

Fəsil 10

Qrafların xətti cəbri

“Əgər insanlar riyaziyyatın sadə olduğuna inanmırlarsa, bu yalnız həyatın nə qədər müəkkəb olduğunu dərk etməmələrindəndir.”

Con fon Neyman

10.1 Giriş

Qraflara veb, sosial şəbəkələr və kommunikasiya şəbəkələri kimi bir çox real dünya mühitində rast gəlinir. Bundan əlavə, bir çox maşın öyrənməsi tətbiqi konseptual olaraq qraflar üzərində optimallaşdırma məsələləri kimi təmsil olunur. Qraf matrisləri maşın öyrənməsində uğurla tətbiq oluna bilən bir sıra faydalı cəbr xassələrinə malikdir. Nüvələr və qrafların xətti cəbri arasında sıx əlaqələr mövcuddur; hər iki sahəyə təbii şəkildə aid edilən klassik tətbiqlərdən biri *spektral klasterləşməkdir* (bax: Bölmə 10.5).

Bu fəsil aşağıdakı kimi qurulmuşdur. Növbəti bölmədə qrafların əsasları və onların qonşuluq matrisləri vasitəsilə təsviri verilir. Qonşuluq matrislərinin qüvvətlərinin struktur xassələri Bölmə 10.3-də müzakirə olunur. Qraf matrislərinin məxsusi vektorları və məxsusi qiymətləri Bölmə 10.4-də nəzərdən keçirilir. Qraf klasterləşməsinin xətti cəbri Bölmə 10.5-də tədqiq edilir, qraf reyting alqoritmlərinin xətti cəbri isə Bölmə 10.6-da araşdırılır. Zəif əlaqəlilik xassələrinə malik qrafların xətti cəbri Bölmə 10.7-də şərh olunur. Qrafların maşın öyrənməsində tətbiqləri Bölmə 10.8-də müzakirə edilir. Bölmə 10.9-da isə ümumi xülasə verilmişdir.

10.2 Qraf əsasları və qonşuluq matrisləri

Bəzən şəbəkə də adlandırılan qraf obyektlər arasındakı “münasibətləri” təsvir etmək üçün istifadə olunan strukturudur. Obyektlər veb-səhifələr, sosial şəbəkə iştirakçıları və ya kimyəvi elementlər kimi istənilən tipdə ola bilər. Eynilə, münasibətlər də veb-keçidlər, sosial şəbəkə dostluq əlaqələri və ya kimyəvi rabitələr kimi (müvafiq) tətbiq sahəsinə uyğun tipdə ola bilər. Məsələn, asetaminofen kimyəvi birləşməsi və onunla əlaqəli qraf strukturu müvafiq olaraq Şəkil 10.1(a) və (b)-də təsvir edilmişdir. Sosial şəbəkəni təmsil edən qraf Şəkil 10.1(c)-də göstərilmişdir.





Figure 10.1: Examples of undirected graphs

Şəkil 10.1: İstiqamətlənməmiş qraf nümunələri



Şəkil 10.2: İstiqamətlənmiş qraf

Qrafdakı obyektlər **verticles** (təpələr), onlar arasındakı münasibətlər isə **edges** (tillər) adlanır. Təpə bəzən həm də **node** (qovşaq) adlandırılır. Bu kitab boyu biz “təpə” və “qovşaq” terminlərini qarşılıqlı əvəz olunan şəkildə işlədirik. G qrafı V təpələrin (qovşaqların) çoxluğu və E tillərin çoxluğu olmaqla (V, E) cütü ilə işarə olunur. Əgər qraf n təpəyə malikdirsə, təpələrin $V = \{1, \dots, n\}$ olduğu qəbul edilir. Eynilə, hər bir $(i, j) \in E$ tili i və j təpələri arasındakı əlaqəni təmsil edir.

Qraflar *istiqamətlənmiş* və ya *istiqamətlənməmiş* ola bilər. İstiqamətlənmiş qraflarda hər bir tilin öz istiqaməti olur. Məsələn, veb-keçidlərin mənbə səhifədən təyinat səhifəsinə doğru istiqaməti var. Tilin mənbəyi onun **quyruğu** (tail), təyinat yeri isə **head** (*baş hissəsi*) adlandırılır. Buna görə də tillər oxlar vasitəsilə göstərilir, burada baş hissə ox ucunu ehtiva edən tərəfə uyğun gəlir. İstiqamətlənmiş qrafın nümunəsi Şəkil 10.2-də təsvir edilmişdir. Digər tərəfdən, istiqamətlənməmiş qraflarda tillərin istiqaməti yoxdur. Məsələn, Facebook dostluq əlaqəsi və ya kimyəvi rabitənin istiqaməti yoxdur. Şəkil 10.1-də təsvir edilən bütün qraflar istiqamətlənməmiş qraflardır. İstiqamətlənməmiş qraf hər bir istiqamətlənməmiş tili əks istiqamətlərdə olan bir cüt istiqamətlənmiş tillə əvəz etməklə istiqamətlənmiş qrafa çevrilə bilər.

Nəhayət, qraflar *çəkili* və ya *çəkisiz* ola bilər. Çəkisiz qrafda iki təpə arasında til ya mövcud ola bilər, ya da olmaya bilər və müəyyən bir til ilə əlaqəli hər hansı “güc” mövcud deyil. Cəbri baxımdan, təsvir binar xarakter daşıyır və bir cüt təpə arasındakı münasibət həmin cüt arasında tilin olub-olmamasından asılı olaraq 1 və ya 0 qiymətini alır. Digər tərəfdən, bir çox tətbiqlərdə münasibətin özünəməxsus çəkisi ola bilər. Məsələn, kimyəvi rabitə paylaşılan elektronların sayına uyğun gələn gücə malikdir. Müvafiq olaraq, çəkilər Şəkil 10.1(b)-də göstərilmişdir. E-poçt şəbəkəsində bir iştirakçıdan digərinə olan tilin çəkisi həmin til boyunca göndərilən mesajların sayına uyğun gələ bilər. Çəkili qraflar daha ümumi xarakter daşıdığından, bu fəsilə müzakirə olunan qraflar həmişə mənfii olmayan çəkilərlə əlaqələndirilir.

İstiqamətlənməmiş qrafda təpənin *dərəcəsi* həmin təpəyə bitişik olan tillərin sayı kimi təyin edilir. Məsələn, Şəkil 10.1(c)-də Semə uyğun gələn təpənin dərəcəsi 4-dür. Hər bir til iki təpəyə insident olduğundan, m tili olan istiqamətlənməmiş qrafda təpələrin dərəcələrinin cəmi həmişə $2m$ -ə bərabərdir. İstiqamətlənmiş qrafın halında təpənin *daxilolma dərəcəsi* və *xaricolma dərəcəsi* haqqında danışmaq məntiqlidir. Təpənin daxilolma dərəcəsi həmin təpəyə daxil olan tillərin sayı, xaricolma dərəcəsi isə xaric olan tillərin sayıdır. Məsələn, Şəkil 10.2-də 1 nömrəli təpənin daxilolma dərəcəsi 1, xaricolma dərəcəsi isə 2-dir. Bütün təpələr üzrə daxilolma dərəcələrinin cəmi və bütün təpələr üzrə xaricolma dərəcələrinin cəmi hər ikisi til sayı olan m -ə bərabərdir. Bunun səbəbi hər bir tilin daxil olan til kimi məhz bir təpəyə, xaric olan til kimi isə bir təpəyə insident olmasıdır. Təpə dərəcələrinin bütün tərifləri hər bir til üçün standart 1 çəkisi əvəzinə tillərin çəkilərini toplamaqla çəkili hala ümumiləşdirilə bilər.

Qraflarda əsas strukturlar

Walk (addım) elə bir $i, i_1, \dots, i_k$ təpələr ardıcılığıdır ki, hər bir i_r -dən i_{r+1} -ə qədər til mövcud olsun. İstiqamətlənmiş qraflarda tilin quyruğu i_r -də, baş hissəsi isə i_{r+1} -də yerləşməlidir. İstiqamətlənməmiş qraflarda tili hər iki istiqamətdə keçmək mümkündür. Gəzinti daxilində təpələrin təkrar olunmasına heç bir məhdudiyyət qoyulmur. Şəkil 10.2-də təpələrin 2, 3, 1, 2, 4 ardıcılığı gəzintidir. Yol (path) elə bir $i_1, i_2, \dots, i_k$ təpələr ardıcılığıdır ki, hər bir i_r -dən i_{r+1} -ə til mövcud olsun və təpələr təkrar olunmasın. İstiqamətlənmiş qraflarda tillərin istiqaməti i_r -dən i_{r+1} -ə doğru olmalıdır. Buna görə də hər bir yol gəzintidir, lakin əksi doğru deyil. Şəkil 10.2-də 3, 1, 2, 4 ardıcılığı yoldur. Çevrə və ya sirkul (cycle) elə $i_1, i_2, \dots, i_k$ təpələr ardıcılığıdır ki, hər ardıcıl təpə cütü arasında til mövcud olsun, $i_1 = i_k$ ödənsin və başqa təkrar olunan təpə olmasın. Başqa sözlə, çevrə istiqamətlənmiş qrafda təpələrin qapalı və istiqamətlənmiş "dövrəsidir". Çevrə həm də gəzintinin xüsusi halıdır. İstiqamətlənməmiş qraflar üçün çevrə sadəcə istiqamətlənməmiş tillərin qapalı dövrəsidir. İstiqamətlənmiş qrafda çevrədəki bütün tillərin istiqaməti eyni olmalıdır. Çevrələri ehtiva etməyən istiqamətlənmiş qraflar istiqamətlənmiş asiklik qraflar adlandırılır. Məsələn, üç təpəni $\{1, 2, 3\}$ və istiqamətlənmiş $(1, 2)$, $(1, 3)$ və $(2, 3)$ tillərini ehtiva edən istiqamətlənmiş qrafa baxaq. Bu qraf heç bir istiqamətlənmiş çevrəni ehtiva etmir və buna görə də istiqamətlənmiş asiklik qrafıdır.

Qrafın *altqrafı (subgraph)* qrafdakı təpələrin və tillərin istənilən alt çoxluğundan ibarət olan qrafdır. Qeyd etmək lazımdır ki, əgər hər hansı bir til altqrafa daxil edilirsə, həmin tilin son nöqtələri olan təpələr də altqrafa daxil edilməlidir. $G=(V,E)$ qrafının $V' \subseteq V$ təpələr çoxluğu tərəfindən *induksiya* olunan altqrafı elə $G'=(V',E')$ qrafıdır ki, burada $E' \subseteq E$ çoxluğu V' -dəki təpələr arasındakı bütün tilləri özündə ehtiva edir.

Əlaqəlilik və Diametr

İstiqamətləndirilməmiş qraf hər bir təpə cütü arasında bir yol mövcud olduqda **əlaqəli (connected)** qraf adlanır. Əlaqəli olmayan istiqamətləndirilməmiş qraf bir neçə **əlaqəli komponentə (connected components)** bölünə bilər. Əlaqəli komponent ilkin qrafın təpələr çoxluğunun bir alt çoxluğudur və elə seçilir ki, həmin təpə çoxluğu tərəfindən induksiya olunan altqraf əlaqəli olsun. Həm əlaqəli, həm də əlaqəsiz istiqamətləndirilməmiş qraflara

nümunələr müvafiq olaraq Şəkil 10.3(a) və 10.3(b)-də göstərilmişdir. Şəkil 10.3(b)-dəki qrafın **iki əlaqəli komponenti** vardır.

İstiqamətləndirilmiş qraf hər bir təpə cütü arasında **hər iki istiqamətdə** istiqamətləndirilmiş yol mövcud olduqda **strongly connected (güclü əlaqəli)** qraf adlanır. Başqa sözlə, verilmiş istənilən $[i, j]$ təpə cütü üçün i -dən j -yə bir yol mövcud olmalı və eyni zamanda j -dən i -yə də bir yol mövcud olmalıdır. Məsələn, təpələrin vahid dövrə (**cycle**) təşkil etdiyi qraf güclü əlaqəlidir. Digər tərəfdən, təpələrdən ibarət tək istiqamətləndirilmiş yol və ya **istiqamətləndirilmiş dövrəsüz qraf (directed acyclic graph)** güclü əlaqəli deyil. Bunun səbəbi bəzi sıralanmış təpə cütləri arasında istiqamətləndirilmiş yolların mövcud olmamasıdır. Şəkil 10.2-dəki qraf güclü əlaqəli deyil, çünki (7) təpəsindən (9) təpəsinə istiqamətləndirilmiş yol mövcud deyil. Daha sonra görəcəyimiz kimi, **güclü əlaqəli qraflar faydalı cəbri xassələrə (algebraic properties)** malikdir.

İstiqamətləndirilmiş qrafda bir cüt təpə arasındakı **məsafə (distance)** və ya **ən qısa yol (shortest path)** həmin təpələr arasında mövcud olan istiqamətləndirilmiş yol üzərindəki tillərin minimum sayı kimi müəyyən edilir. İstiqamətləndirilmiş qrafın **diametri (diameter)** isə qrafda iki təpə arasındakı ən böyük məsafə kimi müəyyən edilir. Qeyd etmək lazımdır ki, i təpəsindən j təpəsinə olan məsafə j təpəsindən i təpəsinə olan məsafədən fərqli ola bilər. Buna görə də qrafın diametrini hesablamaq üçün qrafda bütün $n(n-1)$ **sıralanmış təpə cütləri** arasındakı məsafələri hesablamaq və onların içərisində ən böyük məsafəni müəyyən etmək lazımdır. Əgər müəyyən bir təpə cütü arasında heç bir istiqamətləndirilmiş yol mövcud deyilsə, qrafın diametri ∞ hesab edilir. Buna görə də istiqamətləndirilmiş qrafın diametrinin sonlu olması üçün qraf **güclü əlaqəli (strongly connected)** olmalıdır. Məsələn, Şəkil 10.2-də göstərilən istiqamətləndirilmiş qrafın diametri ∞ -dir, çünki 7 təpəsindən 9 təpəsinə gedən heç bir istiqamətləndirilmiş yol mövcud deyil.

İstiqamətləndirilməmiş qraflarda (undirected graphs) isə i təpəsindən j təpəsinə olan ən qısa yol məsafəsi j təpəsindən i təpəsinə olan məsafə ilə eynidir. Əgər hər hansı bir təpə cütü arasında yol mövcud deyilsə, bu, qrafın **əlaqəsiz (disconnected)** olduğunu göstərir və həmin təpə cütü arasındakı məsafə ∞ qəbul edilir. İstiqamətləndirilməmiş qrafın **diametri**, hər bir təpə cütü arasındakı ən qısa yol məsafələri içərisindəki maksimum qiymətdir. Əlaqəsiz qrafın, məsələn Şəkil 10.3(b)-də göstərilən qrafın diametri isə ∞ -dir.

Qrafın Qonşuluq Matrisi

İstiqamətləndirilməmiş qrafın qonşuluq matrisi istiqamətləndirilmiş qrafın qonşuluq matrisinin xüsusi halıdır, çünki hər bir istiqamətləndirilməmiş til əks istiqamətlərdə yönəlmiş və eyni çəkiyə malik iki istiqamətləndirilmiş tillə əvəz edilə bilər. Buna görə də əvvəlcə istiqamətləndirilmiş qrafların daha ümumi halını nəzərdən keçirəcəyik.

n təpəsi və m tili olan istiqamətləndirilmiş qraf üçün $A=[a_{ij}]$ şəklində $n \times n$ ölçülü kvadrat matris təyin edilir. Bu matrisdə a_{ij} qiyməti i təpəsindən j təpəsinə gedən tilin çəkisini göstərir. Əgər i təpəsindən j təpəsinə heç bir til mövcud deyilsə, həmin elementin qiyməti 0 qəbul edilir. Buna görə də m tili olan istiqamətləndirilmiş qrafın qonşuluq matrisində m sıfırdan fərqli element olur. Çəkisiz qraflar üçün matrisdəki bütün elementlər 0 və ya 1 qiymətini alır.

Qonşuluq matrisinin diaqonal elementlərinin 0 olması adi haldır, çünki qraflarda özünəqayıdan tillər self-loops olduqca nadir rast gəlinir. İstiqamətləndirilmiş qrafın qonşuluq matrisi, adətən, simmetrik olmur, çünki a_{ij} və a_{ji} qiymətləri, bir qayda olaraq, bir-birinə bərabər deyil. Digər tərəfdən, m tili olan istiqamətləndirilməmiş qrafın qonşuluq matrisində $2m$ sıfırdan fərqli element olur və bu matris simmetrikdir, çünki a_{ij} və a_{ji} eyni qiymətə malikdir. İstiqamətləndirilməmiş qrafların qonşuluq matrislərinin simmetrik olması onların xətti cəbr baxımından təhlilini sadələşdirir, çünki belə matrislər həqiqi qiymətli və ortonormal xüsusi vektorlara (eigenvectors) malikdir.

Normallaşdırılmış Qonşuluq Matrisləri

Qrafın qonşuluq matrislərinin normallaşdırılmasının bir neçə üsulu mövcuddur. Normallaşdırmanın əsas məqsədi çoxsaylı insident tillərə malik olan bir neçə təpənin qrafın cəbri xassələrinə həddindən artıq təsir göstərməsinin qarşısını almaqdır. Real dünyadakı qrafların əksəriyyətində dərəcələrin paylanması *qüvvət qanununa* (*power-law degree distribution*) tabe olur [43]. Bunun nəticəsində təpələrin çox kiçik bir hissəsinin dərəcələrinin cəmi, çox vaxt, bütün qrafdakı təpələrin dərəcələri cəminin böyük əksəriyyətini təşkil edir. Nəticədə, məhz bu təpələrə insident olan tillərin strukturu bütün şəbəkənin təhlilinə və ya şəbəkəyə tətbiq edilən maşın öyrənməsi alqoritminin nəticələrinə dominant təsir göstərir. Bu isə arzuolunan deyil, çünki yüksək dərəcəli təpələrin struktur davranışı çox vaxt spam və digər əhəmiyyətsiz / küylü (noisy) tillərdən qaynaqlanır.

Normallaşdırmanın bəzi formaları ehtimallı interpretasiyaya malikdir və bu xüsusiyyət onları real tətbiqlərdə faydalı edir. Normallaşdırmanın ilk növü *asimmetrik normallaşdırma* (**asymmetric normalization**) adlanır və burada hər bir sətir elementlərinin cəmi 1-ə bərabər olacaq şəkildə normallaşdırılır. Bunun üçün hər bir sətirin elementləri toplanır və həmin sətirdəki hər bir element bu cəmə bölünür. Bu normallaşdırmanın nəticəsində *stoxastik keçid matrisi* (**stochastic transition matrix**) əldə edilir; bu matris qonşuluq matrisini Markov zəncirinin keçid matrisinə çevirir. Bu keçid matrisi qraf üzərində *təsadüfi gedişi* (**random walk**) müəyyən edir; burada hər bir təpədəki çıxan keçid ehtimalları həmin til boyunca hərəkət etmə ehtimalını göstərir. Nəticədə alınan qraf **təsadüfi gediş qrafı** (**random walk graph**) adlanır. Qeyd etmək lazımdır ki, bu növ normallaşdırma istiqamətləndirilməmiş qraf üçün ilkin qonşuluq matrisi simmetrik olsa belə, normallaşdırılmış matrisdə asimmetrik çəkirlərin yaranmasına səbəb olur. Asimmetrik normallaşdırmaya nümunə Şəkil 10.4-də göstərilmişdir: burada ikili til çəkirlərinə malik ilkin qraf solda, normallaşdırılmış qraf, yəni təsadüfi gediş qrafı isə sağda göstərilmişdir. Qeyd etmək maraqlıdır ki, bu növ asimmetrik normallaşdırma istiqamətləndirilmiş qrafa da tətbiq edilə bilər. Bu halda hər bir tilin çəkisi həmin *təpədən çıxan tillərin* çəkirlərinin cəminə bölünür. Burada da məqsəd hər bir tilin çəkisini verilmiş təpədən həyata keçirilən təsadüfi gediş ehtimalı kimi interpretasiya etməkdir.

Simmetrik normallaşdırma (**symmetric normalization**), ümumiyyətlə, istiqamətləndirilməmiş qraflar üçün müəyyən edilir. Buna görə də simmetrik qonşuluq matrisindən başlanılır və normallaşdırma prosesi zamanı onun simmetriyasının qorunması məqsəd qoyulur. Simmetrik normallaşdırmada i -ci sətirin mənfi olmayan elementləri toplanaraq δ_i cəmi əldə edilir. Matris simmetrik olduğundan, i -ci sütundakı elementlərin cəmi də δ_i -yə bərabərdir. Başqa sözlə, aşağıdakı ifadəyə sahibik:

$$\delta_i = \sum_{j=1}^n a_{ij} = \sum_{j=1}^n a_{ji}$$

Simmetrik normallaşdırmada hər bir matris elementi onun sətrinin və sütununun cəmlərinin *həndəsi ortasına* bölünür. Nəticədə alınan oxşarlıq qiyməti s_{ij} aşağıdakı kimi müəyyən edilir:

$$s_{ij} = \frac{a_{ij}}{\sqrt{\delta_i \delta_j}}$$

Qeyd etmək lazımdır ki, asimmetrik normallaşdırmada həmişə $p_{ij} = a_{ij}/\delta_i$, ifadəsindən istifadə edilir və buna görə də hər bir sətrin elementlərinin cəmi 1-ə bərabər olur. Burada p_{ij} təsadüfi gediş qrafında i təpəsindən j təpəsinə keçid ehtimalını ifadə edir.

Yuxarıda qeyd olunan normallaşdırmaları cəbri şəkildə matrislərin vurulması formasında da ifadə etmək mümkündür. $A = [a_{ij}]$ ilkin $n \times n$ ölçülü (istiqamətləndirilməmiş) qonşuluq

matrisi, Δ isə i -ci diaqonal elementi $\delta_i = \sum_j a_{ij}$ olan diaqonal $n \times n$ ölçülü matris olsun. Δ matrisi

dərəcə matrisi (degree matrix) adlanır. Qeyd etmək lazımdır ki, dərəcə matrisi tillərin çəkilişləri a_{ij} haqqında məlumatı özündə ehtiva edir; Δ matrisinin diaqonal elementlərində insident tillərin sayı deyil, onların ümumi çəkisi göstərilir. Bəzən Δ matrisi *çəkiliş dərəcə matrisi (weighted degree matrix)* adlandırılır, lakin sadəcə “dərəcə matrisi” ifadəsinin istifadəsi daha geniş yayılmışdır. $P = [p_{ij}]$ asimmetrik şəkildə normallaşdırılmış stoxastik keçid matrisi, $S = [s_{ij}]$ isə simmetrik şəkildə normallaşdırılmış qonşuluq matrisi olsun. Bu halda asimmetrik və simmetrik normallaşdırılmış matrislər aşağıdakı kimi müəyyən edilir:

$$P = \Delta^{-1} A \quad \text{Assimmetrik Normalizasiya}$$

$$S = \Delta^{-1/2} A \Delta^{-1/2} \quad \text{Simmetrik Normalizasiya}$$

Görəcəyimiz kimi, bir-biri ilə əlaqəli olan bu iki matris klasterləşdirmə (clustering), təsnifat (classification) və *PageRank* hesablanması da daxil olmaqla, şəbəkə tətbiqlərinin bir çoxunda mühüm rol oynayır.

10.3 Qonşuluq matrislərinin qüvvətləri

Hər bir elementinin 0 və ya 1 olduğu istiqamətlənmiş qrafın binar qonşuluq matrisi A -ya baxaq. A matrisinin qüvvətləri müəyyən uzunluqlu gəzintilərin sayı ilə əlaqədardır:

Xəssə 10.3.1 *Tutaq ki, A qrafın binar qonşuluq matrisidir. A^k matrisinin (i, j) -inci elementinin qiyməti i -dən j -yə qədər olan, uzunluğu dəqiq k olan gəzintilərin sayına bərabərdir.*

Bu nəticə riyazi induksiya üsulu ilə göstərilə bilər. Aydın məsələdir ki, $A^1 = A$ uzunluğu dəqiq 1 olan bütün gəzintiləri ehtiva edir. İndi isə, əgər A^k -nın (i, j) -inci elementi i -dən j -yə qədər olan uzunluğu k olan gəzintilərin sayını ehtiva edirsə, uzunluğu $(k + 1)$ olan gəzintilərin sayı

i -dən j -yə qoşulmuş bütün təpələrə (yəni, A -nın j -ci sütununda 1 qiymətinə malik bütün təpələrə) qədər olan uzunluğu k olan gəzintilərin sayını toplamaqla əldə edilə bilər. Bu qiymət dəqiq şəkildə $A^k A = A^{k+1}$ matrisinin (i, j) -inci elementi ilə verilir. Tillər çəkili olduqda nə baş verir? Belə bir halda, A^k -nın qiyməti çəkili gəzintilərin sayına bərabərdir, burada hər bir gəzintinin töhfəsi həmin gəzinti üzərindəki a_{ij} qiymətlərinin hasilinə bərabərdir.

i -dən j -yə qədər uzunluğu ən çox t olan gəzintilərin sayı $W(t) = \sum_{k=0}^t A^k$ matrisində yerləşir.

Nəzərə alın ki, A^0 vahid matrisidir və biz onu cəmləməyə daxil edirik, çünki hər bir təpə uzunluğu 0 olan gəzinti ilə özündən əlçatandır. Bir çox hallarda sıfırıncı tərtib həddi buraxılır, çünki gəzintilərin sıfırdan fərqli uzunluğa malik olduğu qəbul edilir. Ümumiyyətlə, t artdıqca bu cəmləmə yığılmır. Məsələn, əgər A iki təpədən ibarət çevrəyə uyğun gəlsə, aşağıdakı ifadəni göstərmək asandır:

Bunun səbəbi ondan ibarətdir ki, verilmiş sayda cüt addımda bir təpədən yenidən həmin təpəyə qayıtmağın yalnız bir yolu, verilmiş sayda tək addımda isə iki təpə arasında hərəkət etməyin yalnız bir yolu mövcuddur. Bu matrislər üzərində sonsuz cəmləmə aparıldıqda yaxınlaşan cəm əldə edilmir. Bundan əlavə, A^r matrisinin elementləri də sonsuz cəmləmə zamanı (bəzi matris növlərində) həddindən artıq böyüyə bilər.

Lakin $\gamma < 1$ şərtini ödəyən sönmə əmsalının (decay factor) tətbiq edilməsi ilə bu cəmin yaxınlaşmasını təmin etmək mümkündür. Semantik baxımdan bu o deməkdir ki, uzunluğu r olan gediş γ^r əmsalı ilə çəkiləndirilir. Daha uzun gedişlərin sayı çox ola bilsə də, sönmə əmsalı sonsuz cəmin nəhayət yaxınlaşmasını təmin edir. Aydındır ki, yaxınlaşmanı təmin etmək üçün seçilməli olan γ qiyməti qrafın struktur xassələrindən asılıdır; maraqlıdır ki, bu struktur xassələri ilkin qonşuluq matrisinin **xüsusi qiymətlərinin parçalanması (eigendecomposition)** vasitəsilə ifadə oluna bilər. γ -nın A matrisinin mütləq qiymətcə ən böyük xüsusi qiymətinin tərsindən kiçik seçilməsi $(\gamma^A)^k$ qüvvətlərinin sonsuz cəmləmə zamanı yaxınlaşmasını təmin edir. Başqa sözlə, $\gamma < 1$ multiplikativ əmsalı vasitəsilə gedişlərin çəkirlərinə sönmə tətbiq edilir və daha sonra təpə cütü arasındakı bütün gedişlərin çəkirləri toplanır.

Bu nəticə ondan irəli gəlir ki, əgər λ , A matrisinin xüsusi qiymətidirsə, onda $\gamma\lambda$, $A_\gamma = \gamma A$ matrisinin xüsusi qiymətidir. Bunun səbəbi aşağıdakı bərabərlikdir:

$$\det(A_\gamma - \lambda\gamma I) = \gamma^n \det(A - \lambda I)$$

Nəticə etibarilə, γ qiymətini A matrisinin xüsusi qiymətlərinin mütləq qiymətləri arasında ən böyük qiymətin tərsindən kiçik seçməklə, $A_\gamma = \gamma A$ matrisinin xüsusi qiymətlərinin mütləq qiymətləri arasında ən böyük qiymətin 1-dən ciddi şəkildə kiçik olması təmin edilir. Aşağıdakı nəticə asanlıqla göstərilə bilər:

Teorem 10.3.1. A elə bir matris olsun ki, onun bütün xüsusi qiymətlərinin mütləq qiyməti $\gamma < 0$ üçün $1/\gamma$ -dən kiçik olsun. Onda aşağıdakı nəticə doğrudur:

$$\lim_{r \rightarrow \infty} (\gamma A)^r = 0$$

İsbatın qısa izahı: γA matrisini A_γ ilə işarə edək. Bu matrisin bütün xüsusi qiymətlərinin mütləq qiyməti 1-dən kiçikdir. İstənilən matris, xüsusi qiymətləri kompleks ola biləcəyi halda belə, **Jordan normal formasına** (bax: Bölmə 3.3.3) aşağıdakı kimi gətirilə bilər:

$$A_\gamma = VJV^{-1}$$

Burada J , **Jordan normal formasında** olan yuxarı üçbucaq matrisdir və onun diaqonal elementlərində (mümkün kompleks) xüsusi qiymətlər yerləşir; bu xüsusi qiymətlərin hər birinin mütləq qiyməti 1-dən kiçikdir. Bu halda aşağıdakı ifadəni göstərmək olar:

$$A_\gamma^r = VJ^rV^{-1}$$

$r \rightarrow \infty$ olduqda J^r matrisinin 0-a yaxınlaşdığı göstərilə bilər. Buna görə də A_γ^r matrisi də 0 matrisinə yaxınlaşır. Bu nəticə istənilən təpə cütü arasında gedilərin sönümlənmə ilə çəkiləndirilmiş cəmini hesablamaq üçün bir üsul təqdim edir.

Teorem 10.3.2. Qonşuluq matrisi A olan istiqamətləndirilmiş qraf verilmiş olsun və A matrisinin ən böyük xüsusi qiyməti $1/\gamma$ -dən kiçik olsun. O zaman hər bir təpə cütü arasındakı bütün sönümlənmiş gedilərin çəkili cəmi aşağıdakı $(I - \gamma A)^{-1} - I$ matrisdə öz əksini tapır:

$$\sum_{r=1}^{\infty} (\gamma A)^r = (I - \gamma A)^{-1} - I$$

İsbatın qısa izahı: γA matrisinin bütün xüsusi qiymətlərinin mütləq qiyməti 1-dən kiçikdir. γA matrisinin hər bir xüsusi qiymətinə $(I - \gamma A)$ matrisində uyğun xüsusi qiymət qarşılıq gəlir və bu iki xüsusi qiymətin cəmi eyni xüsusi vektor üçün 1-ə bərabərdir. Buna görə də $(I - \gamma A)$ matrisinin bütün xüsusi qiymətləri sıfırdan fərqlidir və matris sinqulyar deyil. Başqa sözlə, yuxarıdakı tənliyin hər iki tərəfini $(I - \gamma A)$ ilə vurmaq olar və bu, yuxarıdakı nəticənin doğruluğuna təsir etmir. Hər iki tərəfin $(I - \gamma A)$ ilə vurulması nəticəsində hər iki tərəfdə γA matrisi alınır. Bu da nəticəni sübut edir. $((I - \gamma A)^{-1} - I)$ matrisi çox faydalıdır, çünki onun (i, j) -ci elementi i təpəsindən j təpəsinə olan dolaylı əlaqəlilik səviyyəsi haqqında məlumat verir; hətta bu təpə cütü birbaşa əlaqəli olmadıqda belə. Bu matris təpə cütləri arasındakı bütün **Katz ölçülərini (Katz measures)** özündə ehtiva edir. Katz ölçüsü, ümumiyyətlə, istiqamətləndirilməmiş qraflar üçün istifadə olunur, baxmayaraq ki, istiqamətləndirilmiş qraflara da tətbiq edilə bilər.

Tərif 10.3.1 (Katz ölçüsü). İstiqamətləndirilməmiş qrafın A qonşuluq matrisi verildikdə, i və j təpələri arasındakı Katz ölçüsü $((I - \gamma A)^{-1} - I)$ matrisinin (i, j) -ci elementidir. Burada γ Katz ölçüsünün hesablanmasında istifadə olunan sönümlənmə parametridir.

Katz ölçüsündən **əlaqə proqnozlaşdırılması (link prediction)** üçün istifadə edilə bilər. Bu məsələdə məqsəd müəyyən bir qrafda (məsələn, sosial şəbəkədə) gələcəkdə aralarında əlaqələrin yaranma ehtimalı yüksək olan təpə cütələrini müəyyən etməkdir. Aydındır ki, təpə cütü arasında çoxlu sayda (qısa) gediş mövcuddursa, gələcəkdə onların arasında əlaqənin yaranma ehtimalı daha yüksəkdir. Məsələn, sosial şəbəkələrdə insanın dostlarının dostları ilə əlaqə yaratması daha ehtimallıdır.

Əlaqə proqnozlaşdırılması məsələsinə gizli əks əlaqə (implicit feedback) ilə tövsiyə məsələsinə bənzər şəkildə yanaşmaq olar. Bu məsələni həll etmək üçün əvvəlcə A matrisindəki sıfırdan fərqli elementlərin kiçik bir hissəsini 0-a çevirərək A' matrisini əldə edirik və həmin tilləri A_v validasiya çoxluğunda saxlayırıq. Həmçinin A -dakı bəzi sıfır elementlərə uyğun gələn tilləri A_v -yə əlavə edirik. Müxtəlif γ qiymətləri üçün $(I - \gamma A')$ matrisinin tərsini hesablamaq və A_v validasiya çoxluğundakı əlaqə proqnozlarının ən dəqiq olduğu γ qiymətini seçmək olar. γ qiyməti müəyyən edildikdən sonra əlaqələrin yaranma ehtimalına görə sıralanması məqsədilə bütün tillər daxil olmaqla $(I - \gamma A)^{-1}$ matrisi hesablanır.

Qonşuluq matrisinin qüvvətlərindən həm istiqamətləndirilməmiş, həm də istiqamətləndirilmiş qrafların diametrini və əlaqəliliyini xarakterizə etmək üçün də istifadə edilə bilər. Qeyd edək ki, qrafın diametri d -dirsə, hər bir təpə cütü arasında uzunluğu ən çox d olan yol mövcuddur.

Başqa sözlə, ixtiyari i və j təpə cütü arasındakı ən qısa yolun uzunluğu $r_{ij} \leq d$ -dirsə, $A^{r_{ij}}$ matrisinin (i, j) -ci elementi sıfırdan fərqli olacaq. Bu isə qrafın diametrini qonşuluq matrisinin qüvvətləri baxımından aşağıdakı şəkildə müəyyən etməyə imkan verir.

Xəssə 10.3.2. Qonşuluq matrisi A olan (istiqamətləndirilmiş və ya istiqamətləndirilməmiş) qrafın diametri $\sum_{k=0}^d A^k$ matrisinin bütün elementlərinin sıfırdan fərqli olduğu ən kiçik (d) qiymətidir. İstənilən əlaqəli istiqamətləndirilməmiş qraf və ya güclü əlaqəli istiqamətləndirilmiş qraf üçün d qiyməti ən çox $n - 1$ -ə bərabərdir.

İstiqamətləndirilməmiş qraf əlaqəli olmadıqda və ya istiqamətləndirilmiş qraf güclü əlaqəli olmadıqda, qrafın diametri ∞ -dir. Sonlu diametrə malik bütün qrafların diametri ən çox $n - 1$ olduğundan, bu xüsusiyyət qonşuluq matrisinin qüvvətlərindən istifadə etməklə (istiqamətləndirilmiş və ya istiqamətləndirilməmiş) qrafın əlaqəliliyini yoxlamaq üçün sadə üsul təqdim edir.

Teorem 10.3.3 (İstiqamətləndirilməmiş qrafın əlaqəliliyi). $n \times n$ ölçülü qonşuluq matrisi A olan istiqamətləndirilməmiş qraf o zaman və yalnız o zaman əlaqəlidir ki, $\sum_{k=0}^{n-1} A^k$ matrisinin bütün elementləri sıfırdan fərqli olsun.

Teorem 10.3.4 (İstiqamətləndirilmiş qrafın güclü əlaqəliliyi). $n \times n$ ölçülü qonşuluq matrisi A olan istiqamətləndirilmiş qraf o zaman və yalnız o zaman güclü əlaqəlidir ki, $\sum_{k=0}^{n-1} A^k$ matrisinin bütün elementləri sıfırdan fərqli olsun.

Əlaqəliliyi yoxlamaq üçün sadə yanaşmalardan biri bütün Katz ölçülərini özündə ehtiva edən matrisi hesablamaq və onun diaqonaldan kənar bütün elementlərinin sıfırdan fərqli olub-olmadığını yoxlamaqdır.

Əlaqəli olmayan istiqamətləndirilməmiş qraflarda və ya güclü əlaqəli olmayan

istiqamətləndirilmiş qraflarda $\sum_{k=0}^{n-1} A^k$ matrisində müəyyən təpə qrupları arasında çatışmayan

tillər mövcud olacaq. $\sum_{k=0}^{n-1} A^k$ matrisindəki bu çatışmayan tillər sıfırdan fərqli elementlərin

müəyyən tipli blok strukturunun yaranmasına səbəb olur. Məsələn, təpələrin 1 və 2 çoxluqlarına bölünə bildiyi istiqamətləndirilmiş qrafı nəzərdən keçirək. Fərz edək ki, 1 və 2 çoxluqlarının daxilindəki təpələr öz aralarında güclü əlaqəlidir. Bundan əlavə, 1-ci çoxluqdakı təpələrdən 2-ci çoxluqdakı təpələrə tillər mövcuddur, lakin əks istiqamətdə heç bir til mövcud deyil. Bu tip qraf güclü əlaqəli deyil və təpələri uyğun şəkildə yenidən sıralamaqla onun qonşuluq matrisi həmişə **blok yuxarı üçbucaq formasına (block upper-triangular form)** gətirilə bilər:

marix elave edeceksen

Qeyd etmək lazımdır ki, diaqonal boyunca yerləşən bloklar həmişə kvadrat formalıdır, lakin diaqonalın üzərində yerləşən bloklar kvadrat olmaya bilər. Matris A neçə dəfə qüvvətə yüksəldilsə də, aşağıdakı sıfır blokunun sıfır olaraq qalacağını yoxlamaq çətin deyil. Eynilə, əlaqəsiz istiqamətləndirilməmiş qrafın qonşuluq matrisi də aşağıdakı kimi blok-diaqonal formaya gətirilə bilər:

matrix elave edeceksen

Bu matrisin istənilən sayda qüvvətini hesablamağın yalnız ayrı-ayrı blokların qüvvətə yüksəldilməsi ilə nəticələndiyini yoxlamaq nisbətən asandır:

matrix elave edeceksen

A_{11} və A_{22} blokları matrislərin vurulması zamanı bir-biri ilə qarşılıqlı əlaqəyə girmir.

10.4 Perron–Frobenius Teoremi

Aşağıda həm istiqamətləndirilmiş, həm də istiqamətləndirilməmiş qraflarda qonşuluq matrislərinin xüsusi vektorlarının bəzi əsas xassələrini nəzərdən keçirəcəyik. Perron–Frobenius teoremi istiqamətləndirilmiş qrafların ümumi halına tətbiq olunur və istiqamətləndirilməmiş qraflar üçün əlavə sadələşdirmələrə malikdir. Bütün qraf qonşuluq matrisləri (istiqamətləndirilmiş və ya istiqamətləndirilməmiş) mənfi olmayan elementlərə malikdir və bunun nəticəsində uyğun xüsusi vektorlar xüsusi xassələrə malik olur. İstiqamətləndirilməmiş qraflar istiqamətləndirilmiş qraflarla müqayisədə daha maraqlı xassələrə malikdir, çünki onların qonşuluq matrislərinin simmetrik olması ortonormal xüsusi vektorların və həqiqi xüsusi qiymətlərin mövcudluğunu təmin edir. İstiqamətləndirilmiş qrafların qonşuluq matrisləri isə həm həqiqi, həm də kompleks xüsusi qiymətlərə malik ola bilər. Bu nəticələr toplusu, ümumiyyətlə, **Perron–Frobenius teoremi** adlandırılır.

Xəssə 10.4.1. İstiqamətləndirilmiş qrafların qonşuluq matrisləri bir və ya bir neçə kompleks xüsusi qiymətə malik ola bilər. Bundan əlavə, kompleks xüsusi qiymətlərə icazə verildikdə belə, istiqamətləndirilmiş qrafın qonşuluq matrisinin diaqonallaşdırıla biləcəyinə zəmanət verilmir.

Diaqonallaşdırıla bilməməyə nümunə olaraq, ardıcıl hər bir təpə cütü $[i, i + 1]$ arasında iki istiqamətli tillərin və 1-ci təpədən 4-cü təpəyə doğru bir istiqamətli tilin olduğu dörd təpəli istiqamətləndirilmiş qrafı nəzərdən keçirək:

matrix elave edəcəksen

Bir istiqamətli til əlavə edilmədikdə, qraf simmetrik olur və həqiqi və ortonormal xüsusi vektorlarla diaqonallaşdırıla bilər. Lakin 1-ci təpədən 4-cü təpəyə doğru yalnız bir tilin əlavə edilməsi qonşuluq matrisini diaqonallaşdırıla bilməyən edir. $\text{Det}(N - \lambda I)$ hesablandıqda göstərmək olar ki, bu matrisin xarakteristik çoxhədlisi $\lambda^4 - 3\lambda^2$ -dir və bu, $\{-\sqrt{3}, \sqrt{3}, 0, 0\}$ xüsusi qiymətlərinə uyğundur. Buna görə də 0 xüsusi qiyməti təkrarlanan xüsusi qiymətdir. Lakin xüsusi qiyməti 0 olan yalnız bir $[0, 1, 0, -1]^T$ xüsusi vektoru mövcuddur, çünki matrisin rəngi 3-ə bərabərdir. Buna görə də bu qonşuluq matrisi diaqonallaşdırıla bilən deyil.

Kompleks xüsusi qiymətlərə malik, diaqonallaşdırıla bilən istiqamətləndirilmiş qrafa nümunə olaraq üç təpədən ibarət istiqamətləndirilmiş dövrə (cycle) ehtiva edən aşağıdakı qonşuluq matrisini nəzərdən keçirək:

matrix elave edəcəksen

Qeyd etmək lazımdır ki, bu matrisin 1 xüsusi qiymətinə uyğun bir həqiqi qiymətli xüsusi vektoru $[1, 1, 1]^T$ mövcuddur. Digər iki xüsusi qiymətin $(-1 + i\sqrt{3})/2$ və $(-1 - i\sqrt{3})/2$ olduğu göstərilə bilər və bunlar açıq şəkildə kompleksdir. Uyğun xüsusi vektorlar da kompleksdir. Xarakteristik çoxhədlisi $\lambda^3 - 1$ olduğuna görə bütün xüsusi qiymətlərin vahidin həqiqi və kompleks kub kökləri olduğu göstərilə bilər. Qeyd etmək maraqlıdır ki, ən azı bir həqiqi xüsusi vektor–xüsusi qiymət cütü əldə etdik. Bundan əlavə, bu xüsusi vektor mütləq qiymətinə görə ən böyük xüsusi qiymətə uyğundur, baxmayaraq ki, digər iki xüsusi qiymətin də modulu 1-ə bərabərdir. Bu təsadüfi deyil. Göstərmək olar ki, istənilən güclü əlaqəli istiqamətləndirilmiş qrafın qonşuluq matrisi ən azı bir həqiqi xüsusi vektor–xüsusi qiymət cütünə malikdir və bu cüt həm də dominant cütdür. Güclü əlaqəli qrafın qonşuluq matrisi **irreduşibl (irreducible)** adlanır.

Tərif 10.4.1 (İrreduşibl matris). İstiqamətləndirilmiş qrafın qonşuluq matrisi o zaman və yalnız o zaman **irreduşibl** adlanır ki, uyğun qraf güclü əlaqəli olsun.

İrreduşibl olmayan qonşuluq matrisi **reduşibl (reducible)** adlanır. Qeyd etmək lazımdır ki, qraf güclü əlaqəli deyilsə (yəni onun qonşuluq matrisi reduşibldirsə), onda ya qraf tamamilə əlaqəsizdir, ya da onun təpələri elə iki çoxluğa bölünə bilər (yəni bir kəsim (cut) yaradıla bilər) ki, bu iki çoxluq arasındakı tillər yalnız bir istiqamətə yönəlsin. Başqa sözlə, matris aşağıdakı **blok yuxarı üçbucaq formasında** ifadə edilə bilər:

matrx elave edəcəksen

İstiqamətləndirilmiş qrafdakı gedisələr baxımından bu o deməkdir ki, A_{12} -dəki tillər vasitəsilə 1-ci blokdan 2-ci bloka keçdikdən sonra 1-ci blokda hər hansı təpəyə geri qayıtmaq mümkün deyil. Yuxarıdakı matrisdə təpələrin elə sıralandığı qəbul edilir ki, bir komponentə aid olan bütün təpələr digər komponentə aid olan bütün təpələrdən əvvəl yerləşsin.

Perron–Frobenius teoremi yalnız güclü əlaqəli qraflara, yəni irreduşibl qonşuluq matrisləri ilə ifadə olunan qraflara tətbiq edilir. Bu nəticənin əsas diqqət mərkəzində mütləq qiyməti ən böyük olan xüsusi vektor dayanır və bu vektor **baş xüsusi vektor (principal eigenvector)** adlandırılır. Qeyd etmək lazımdır ki, asimmetrik matrisin (məsələn, istiqamətləndirilmiş qrafın) sol xüsusi vektorları və sağ xüsusi vektorları bir-birindən fərqlənir. Perron–Frobenius teoreminin ümumi forması aşağıdakı kimi ifadə edilir:

Teorem 10.4.1 (İstiqamətləndirilmiş qraflar üçün Perron–Frobenius teoremi). n təpədən ibarət istiqamətləndirilmiş qraf üçün A mənfi olmayan elementlərə malik kvadrat, irreduşibl qonşuluq matrisi olsun. Onda A matrisinin mütləq qiymətcə ən böyük xüsusi qiymətlərindən biri həmişə həqiqi və müsbətdir ($\lambda_{\max}$ ilə işarə olunur) və bu (müsbət) xüsusi qiymətin çoxqatlılığı 1 -ə bərabərdir. Lakin mütləq qiyməti $\lambda_{\max}$ -ə bərabər olan digər kompleks və ya mənfi xüsusi qiymətlər də mövcud ola bilər. Aşağıdakı nəticələr də doğrudur:

- $\lambda_{\max}$ həqiqi və müsbət xüsusi qiymətinə uyğun yeganə sol xüsusi vektor və yeganə sağ xüsusi vektor yalnız həqiqi və ciddi şəkildə müsbət elementlərdən ibarətdir.
- Həqiqi və müsbət $\lambda_{\max}$ xüsusi qiyməti aşağıdakı şərti ödəyir:

$$\text{average}_i \sum_j a_{ij} \leq \lambda_{\max} \leq \max_i \sum_j a_{ij}$$

$$\text{average}_j \sum_i a_{ij} \leq \lambda_{\max} \leq \max_j \sum_i a_{ij}$$

Bu o deməkdir ki, çəkisiz matrislər üçün ən böyük xüsusi qiymət orta və maksimum **giriş dərəcəsi** (indegree) və **çıxış dərəcəsi** (outdegree) arasında yerləşir. Buna görə də maksimum giriş dərəcəsi ilə maksimum çıxış dərəcəsinin minimumundan ($\lambda_{\max}$) üçün yuxarı sərhəd kimi istifadə etmək olar.

- **Stoxastik keçid matrislərinin xüsusi halı:** Stoxastik keçid matrislərində hər bir təpənin çəkili çıxış dərəcəsi 1 -ə bərabər olduğundan, yuxarıdakı nəticələrə əsasən ən böyük xüsusi qiymət 1 -ə bərabərdir. Stoxastik keçid matrisi P -nin buna uyğun sağ xüsusi vektoru bütün elementləri 1 -ə bərabər olan n -ölçülü sütun vektorudur, çünki P -nin hər bir sətirinin elementlərinin cəmi 1 -ə bərabərdir. Buna uyğun sol xüsusi vektor **PageRank vektoru** adlandırılır və $\bar{\Pi}^T P = \bar{\Pi}^T$ tənliyinin həllidir.

Qeyd etmək lazımdır ki, mütləq qiymətcə ən böyük xüsusi qiymət müsbət olsa da, eyni mütləq qiymətə $\lambda_{\max}$ malik kompleks və ya mənfi xüsusi qiymətlər mövcud ola bilər. Konkret nümunə kimi, Tənlik 10.1-dəki qonşuluq matrisində üç təpədən ibarət istiqamətləndirilmiş dövrəni nəzərdən keçirək. Bu matrisin xüsusi qiymətləri 1-in üç həqiqi və ya kompleks kub köküdür: 1, $(-1 + i\sqrt{3})/2$ və $(-1 - i\sqrt{3})/2$. Hər üç kökün mütləq qiyməti 1-ə bərabərdir. Ümumiyyətlə, göstərmək olar ki, (n) təpədən ibarət istiqamətləndirilmiş dövrə 1-in n həqiqi və kompleks n -ci dərəcəli köklərinə uyğun gələn n xüsusi qiymətə malikdir. Bu qiymətlər $t \in \{0 \dots n-1\}$ üçün $\exp(2i\pi t/n) = \cos(2\pi t/n) + i \sin(2\pi t/n)$ şəklində ifadə oluna bilər. Bütün həqiqi və kompleks xüsusi qiymətlərin mütləq qiyməti 1-ə bərabərdir. Qraf redusibl olduqda, ən böyük (müsbət) xüsusi qiymətə uyğun bir neçə xüsusi vektor mövcud ola bilər. Bundan əlavə, belə halda baş xüsusi vektorun yalnız müsbət elementlərdən ibarət olmasına artıq zəmanət verilmir.

Perron–Frobenius teoreminin sadələşdirilmiş forması istiqamətləndirilməmiş qraflara da tətbiq olunur. İstiqamətləndirilməmiş qraflarda qonşuluq matrisi simmetrikdir və buna görə də bütün xüsusi vektorlar həqiqidir. Bundan əlavə, hər bir istiqamətləndirilməmiş til əvəzinə əks istiqamətlərdə iki istiqamətləndirilmiş til qoyulduqda, qraf istiqamətləndirilmiş şəbəkə kimi nəzərdən keçirildikdə həmişə güclü əlaqəli olur. Buna uyğun olaraq, istiqamətləndirilməmiş qraflar üçün Perron–Frobenius teoremini aşağıdakı kimi ifadə etmək olar:

Nəticə 10.4.1 (İstiqamətləndirilməmiş qraflar üçün Perron–Frobenius teoremi). n təpədən ibarət əlaqəli istiqamətləndirilməmiş qraf üçün A mənfi olmayan qonşuluq matrisi olsun. Onda A matrisinin mütləq qiymətcə ən böyük xüsusi qiyməti $\lambda_{\max}$ həmişə həqiqi və müsbətdir. $\lambda_{\max}$ qiymətinə malik yalnız bir xüsusi qiymət mövcuddur, baxmayaraq ki, eyni mütləq qiymətə malik mənfi xüsusi qiymətin mövcud olması mümkündür. Aşağıdakı nəticələr doğrudur:

- Bütün xüsusi vektorlar və xüsusi qiymətlər həqiqidir. Əgər qrafda özünəqayıdan tillər yoxdursa, xüsusi qiymətlərin cəmi A matrisinin izinə bərabərdir və bu da 0-dır. Buna görə də bəzi xüsusi qiymətlər həmişə mənfi olacaq. $\lambda_{\max}$ xüsusi qiyməti həmişə mütləq qiymətcə ən böyük mənfi xüsusi qiymətdən ən azı onun qədər böyükdür.
- $\lambda_{\max}$ xüsusi qiymətinə uyğun yalnız bir xüsusi vektor mövcuddur. Bu xüsusi vektor yalnız ciddi şəkildə müsbət elementlərdən ibarətdir (zəruri olduqda -1-ə vurmaqla). Yeganəlik o deməkdir ki, $A\bar{\Pi} = \lambda_{\max} \bar{\Pi}$ tənliyinin həlli miqyaslandırma daxilində yeganədir.
- Ən böyük xüsusi qiymət aşağıdakı şərti ödəyir:

$$\text{average}_i \sum_j a_{ij} \leq \lambda_{\max} \leq \max_i \sum_j a_{ij}$$

Bu o deməkdir ki, çəkisiz matrislər üçün ən böyük xüsusi qiymət orta dərəcə ilə maksimum dərəcə arasında yerləşir.

Nəhayət, istiqamətləndirilməmiş qrafların stoxastik keçid matrisləri simmetrik deyildir; lakin onlar törədikləri istiqamətləndirilməmiş (simmetrik) qonşuluq matrislərinin bəzi xassələrini qoruyub saxlayırlar. Məsələn, istiqamətləndirilməmiş qrafların stoxastik keçid matrisləri simmetrik analoqlarında olduğu kimi, həqiqi xüsusi vektorlara və həqiqi xüsusi qiymətlərə malik olmağa davam edir.

Nəticə 10.4.2 (İstiqamətləndirilməmiş qrafların stoxastik keçid matrisləri). $P = \Delta^{-1}A$, $n \times n$ ölçülü A qonşuluq matrisinə və Δ dərəcə matrisinə malik əlaqəli istiqamətləndirilməmiş qrafın normallaşdırılmış keçid matrisi olsun. Aşağıdakı nəticələr doğrudur:

- Bütün xüsusi vektorlar və xüsusi qiymətlər həqiqidir. Mütləq qiymətcə ən böyük xüsusi qiymət həmişə yeganədir və 1-ə bərabərdir, baxmayaraq ki, -1 qiymətinə malik xüsusi qiymətin də mövcud olması mümkündür.
- Xüsusi qiyməti 1 olan yeganə sağ xüsusi vektor bütün elementləri 1-ə bərabər olan nn -ölçülü sütun vektoruna uyğundur. Bu vektor keçid matrisinin hər bir sətrinin cəmi 1-ə bərabər olduğu üçün düzgün sağ xüsusi vektordur.
- tənliyinin sol xüsusi vektor həlli miqyaslandırmaya qədər yeganədir. Bu vektor **PageRank vektoru** adlanır və onun bütün komponentləri ciddi şəkildə müsbətdir.

Qeyd etmək lazımdır ki, ən böyük xüsusi qiyməti 1 olan xüsusi vektor yeganə olsa da, -1 xüsusi qiymətinə uyğun digər xüsusi vektorlar da mövcud ola bilər. Buna görə də mütləq qiymətcə ən böyük xüsusi vektor yeganə deyil. Konkret nümunə kimi, iki təcürdən və onlar arasında bir tək tildən ibarət istiqamətləndirilməmiş qrafın stoxastik keçid matrisini nəzərdən keçirək. Həm qonşuluq matrisi A , həm də stoxastik keçid matrisi P aşağıdakı formaya malikdir:

matrix elave et

Bu qraf iki təcürdən ibarət istiqamətləndirilmiş dövrə ilə eyni qonşuluq matrisinə malikdir. Onun xüsusi qiymətləri -1 və $+1$ -dir.

Normallaşdırılmış qonşuluq matrislərinin xüsusi vektorlarından maşın öyrənməsində spektral klasterləşdirmə və sıralama kimi tətbiqlərdə geniş istifadə olunur. Sol xüsusi vektorlardan təcürərin sıralanması kimi tətbiqlərdə, sağ xüsusi vektorlardan isə spektral klasterləşdirmədə istifadə edilir. Növbəti bölmələrdə əsas diqqət bu məsələlərə yönəldiləcək.

10.5 Qraf matrislərinin sağ xüsusi vektorları

Bu bölmədə *spektral klasterləşmə* adlandırılan qraf klasterləşməsinin xüsusi növü üçün istifadə olunan istiqamətlənməmiş qrafların sağ məxsusi vektorlarının xətti cəbri müzakirə olunur. Bu bölmə boyu həqiqi məxsusi qiymətləri və məxsusi vektorları təmin edən simmetrik qonşuluq matrisinə malik istiqamətlənməmiş qraflarla işlədiyimiz qəbul edilir.

Qonşuluq matrisi A olan istiqamətlənməmiş qrafa baxaq. Qraf klasterləşməsinin hər hansı formasını tətbiq etməzdən əvvəl qonşuluq matrisi A -ya ilkin emal mərhələsi tətbiq edilir. Bu ilkin emal mərhələsinin məqsədi qrafda az çəkili əlaqələri qırmaq və onların çəkiliblərini 0-a bərabərləşdirməkdir. Bu, klasterlərarası əlaqələri differensial olaraq aradan qaldırmağa və klasterləşməni daha təmiz etməyə imkan verir. Bunu həyata keçirməyin bir neçə yolu var ki, onların hər biri hansı əlaqələrin silinəcəyini müəyyən etmək üçün hədd (threshold) parametrindən istifadəni tələb edir.

1. Qonşuluq matrisi A -dakı ϵ hədd qiymətindən kiçik olan bütün sıfırdan fərqli elementlər 0-a bərabərləşdirilir. Başqa sözlə, əgər a_{ij} qiyməti ϵ -dan kiçikdirsə, o, 0 təyin edilir.
2. Hər bir i təpəsi üçün, j istifadəçi tərəfindən müəyyən edilən κ parametrinə əsasən i -nin κ -ən yaxın qonşuları arasında deyilsə, bütün belə a_{ij} elementlərini 0-a çeviririk. Lakin bu dəyişiklik matrisi asimmetrik edəcək. Buna görə də κ -ən yaxın qonşulardan istifadə etmək əvəzinə qarşılıqlı κ -ən yaxın qonşulardan istifadə etməyə üstünlük veririk. Başqa sözlə, a_{ij} və a_{ji} elementlərini yalnız və yalnız i və j təpələri bir-birinin κ -ən yaxın qonşuları olduqda 0-a çeviririk.

Bu tip üsullar sadəcə evristik yanaşmalardır. Son qonşuluq matrisi A simmetrik olduğu müddətdə zəif əlaqələri aradan qaldırmaq üçün demək olar ki, istənilən məntiqli evristik üsuldan istifadə etmək olar. Simmetrik qonşuluq matrisinin saxlanması spektral klasterləşdirmədə həqiqi qiymətli xüsusi vektorların və xüsusi qiymətlərin təmin edilməsi baxımından mühüm əhəmiyyət daşıyır. Bu bölmə boyunca A matrisinin zəif əlaqələrin aradan qaldırıldığı qonşuluq matrisini ifadə etdiyini fərz edəcəyik. Qonşuluq matrisi sadəcə oxşarlıq matrisinin (və ya nüvənin) bir formasıdır, baxmayaraq ki, diaqonal elementləri sıfır olduğuna görə müsbət yarımmüəyyən deyil. Qeyd etmək maraqlıdır ki, çoxölçülü verilənlər çoxluqları tez-tez verilən nöqtələri obyektlər, tillərin çəkiliblərini isə Gauss nüvəsinə əsaslanan oxşarlıq qiymətləri kimi nəzərdən keçirməklə qraflara çevrilir (bax: Fəsil 9). Əslində, zəif əlaqələri aradan qaldırmadan belə bir qraftan istifadə etsək, əldə olunan klasterləşdirmə kernel k -means klasterləşdirməsinə çox oxşar olur (yalnız xüsusiyyət seçimi və normallaşdırma ilə əlaqəli kiçik, detallı fərqlərlə).

Zəif əlaqələrin aradan qaldırılması qonşuluq matrisindəki hər bir elementi digər elementlərin qiymətlərindən asılı vəziyyətə gətirir. Bu tip oxşarlıq funksiyası verilənlərdən asılı nüvə *data-dependent kernel* adlanır. Saf Gauss nüvəsindən (bax: Fəsil 9) fərqli olaraq, verilənlərdən asılı nüvə yalnız özünün iki arqumentinin funksiyası kimi hesablanmır və oxşarlıq matrisinin qalan hissəsindən də asılıdır. Bu bölmədə spektral klasterləşdirməyə bir-birinə ekvivalent olan üç baxış təqdim edirik: nüvəyə əsaslanan baxış, Laplas baxışı və matris faktorizasiyasına əsaslanan baxış.

10.5.1 Spektral Klasterləşdirməyə Nüvə Baxışı

Spektral klasterləşməni müzakirə etməzdən əvvəl, ilk olaraq istiqamətlənməmiş qrafın simmetrik qonşuluq matrisinə oxşarlıq matrisi kimi baxmaqla əldə edilən ən aşkar nüvə

metodunu nəzərdən keçiririk. Bu müzakirə spektral üsulları həmin nüvə metodunun variantları kimi başa düşmək üçün zəmin yaradır. Güman edirik ki, qonşuluq matrisi (zəif əlaqələr silindikdən sonra) $A = [a_{ij}]$ ilə işarə olunur. İstiqamətlənməmiş qrafın $n \times n$ ölçülü qonşuluq matrisi A simmetrik oxşarlıq matrisidir, baxmayaraq ki, onun məxsusi qiymətlərinin cəmi (yəni matrisin izi) 0 olduğundan o, müsbət yarımüeyyən deyil. Buna baxmayaraq, simmetrik qonşuluq matrisini həmişə $A = Q\lambda Q^T$ şəklində diaqonallaşdırmaq və mühəndislik üsulu ilə qurulmuş təsvir kimi sadəcə olaraq Q -nün ilk k sütunundan istifadə etmək olar. k -means kimi istənilən klasterləşmə alqoritmi bu imbedinq (yerləşdirmə) üzərində tətbiq oluna bilər (bax: Bölmə 9.5.1.1). Oxşarlıq matrisinin (yəni qonşuluq matrisinin) müsbət yarımüeyyənliyə malik olmaması bunun nüvə metodu olmadığını güman etməyə əsas verə bilər. Lakin bu, tamamilə düzgün deyil; biz həmçinin ən mənfi məxsusi qiymətin $\gamma > 0$ mütləq qiymətini hər bir diaqonal elementə əlavə etməklə A matrisini şərtləndirə bilərik. $A + \gamma I = Q(\lambda + \gamma I)Q^T$ matrisi tamamilə eyni məxsusi vektorlara malik müsbət yarımüeyyən matrisdir. Məxsusi qiymətlərdən istifadə olunmur. Bu, nüvə hiyləsi (kernel trick) vasitəsilə məxsusi vektorları məxsusi qiymətlərin kvadrat kökü ilə örtülü (implicit) şəkildə miqyaslayan nüvə k -means üsulundan (bax: Bölmə 9.5.2.1) bir qədər fərqlənir. Spektral klasterləşmə məxsusi qiymətlərin miqyaslama effektivə məhəl qoymur və ağardılmış (whitened) təsvirlərlə işləyir (bax: 7-ci fəslə, Bölmə 7.4.6). Bundan əlavə, o, yalnız ilk k məxsusi vektordan istifadə edir və bununla da yumşaq məxsusi qiymət çəkiləndirməsini diskret seçimlə əvəz edir. Bu növ normallaşdırma və əlamət seçimi fərqləri həmişə nüvə hiyləsi əvəzinə (spektral üsullarda olduğu kimi) əlamət mühəndisliyindən istifadə edilən hallarda baş verir.

Yuxarıda müzakirə olunan yanaşma nüvə metodudur (spektral klasterləşmə ilə əlaqəli), lakin o, dəqiq mərtəbədə spektral klasterləşmə deyil. Qonşuluq matrislərindən (oxşarlıq matrisləri kimi) birbaşa istifadə etməyin problemlərindən biri matrisin elementlərində bir neçə təpənin üstünlük təşkil etməsidir. Əksər real dünya qrafları *qüvvət qanunu dərəcə paylanmalarına* [43] tabedir; burada təpələrin kiçik bir hissəsi (adətən 1%-dən azı) qrafda kiçik tillərin əksəriyyətini təşkil edir. Nəticədə, imbedinqdə təpələrin kiçik bir hissəsinin topoloji strukturu üstünlük təşkil edir ki, bu da arzuolunmazdır. Spektral klasterləşmə bu problemi *təpə dərəcəsinin normallaşdırılması* vasitəsilə həll edir.

Simmetrik normallaşdırmada biz i -ci diaqonal elementində $\delta_i = \sum_j a_{ij}$ dərəcəsinə ehtiva edən $n \times n$ ölçülü diaqonal Δ matrisini hesablayırıq. Yüksək dərəcəli təpələrin təsirini azaltmaq məqsədilə hər bir a_{ij} elementi δ_i və δ_j -nin həndəsi ortasına bölünür. Bölmə 10.2-də müzakirə olunduğu kimi, simmetrik normallaşdırılmış oxşarlıq matrisi S aşağıdakı kimi təyin edilir:

$$S = \Delta^{-1/2} A \Delta^{-1/2}$$

Biz bu oxşarlıq matrisini $S = Q_{(s)} \lambda Q_{(s)}^T$ şəklində diaqonallaşdırırıq və sonra imbedinqi ehtiva edən $n \times k$ ölçülü matris $Q_{(s),k}$ kimi $Q_{(s)}$ -nin ilk k sütunundan (yəni ən böyük məxsusi vektorlarından) istifadə edə bilərik. Simmetrik normallaşdırmanı vurğulamaq üçün imbedinqi ehtiva edən $Q_{(s),k}$ matrisinə '(s)' indeksini əlavə edirik. $Q_{(s),k}$ matrisinin i -ci sətiri i -ci təpənin k -ölçülü imbedinqini ehtiva edir. Bu imbedinq Ng-Jordan-Weiss imbedinqi adlanır [98]. k -means kimi hər hansı klasterləşmə alqoritmi bu imbedinqə tətbiq oluna bilər. k -means alqoritmini tətbiq etməzdən dərhal əvvəl $n \times k$ ölçülü $Q_{(s),k}$ matrisinin hər bir sətirini vahid

normaya qədər normallaşdırmaq da geniş yayılmış təcrübədir. Nəzərə alın ki, $Q_{(s),k}$ -nin hər bir sətrinin normallaşdırılması sütunların artıq normallaşdırılmadığı imbedinq matrisinin yaranması ilə nəticələənəcəkdir.

Bu yanaşmanın əlaqəli bir variantı simmetrik normallaşdırılmış matris əvəzinə stoxastik keçid matrisindən istifadə edən *Shi-Malik alqoritm*dir [115]. Başqa sözlə, normallaşdırma asimmetrikdir:

$$P = \Delta^{-1}A$$

İnsan P -yə oxşarlıq matrisi kimi də baxa bilər; lakin əsas problem onun asimmetrik olmasıdır; buna görə də onun müsbət yarımüyyənliyindən danışmaq belə məntiqli deyil.

9-cu fəslin 9.3.3-cü bölməsində müzakirə olunduğu kimi, əgər oxşarlıq tərifini asimmetriyaya imkan verəcək şəkildə zəiflətməyə razı olsaq, asimmetrik oxşarlıq matrislərindən imbedinqləri çıxarmaq hələ də mümkündür. Bu halda, asimmetrik dekompozisiyadan istifadə olunur:

$$P = Q_{(a)} \lambda Q_{(a)}^{-1}$$

Stoxastik keçid matrisləri üçün Perron-Frobenius teoremine (bax: Nəticə 10.4.2) əsasən, qeyd etmək lazımdır ki, bu dekompozisiya həmişə həqiqi qiymətli məxsusi vektorları və məxsusi qiymətləri ehtiva edir. $Q_{(a)}$ matrisinin sütunları P -nin sağ məxsusi vektorlarını ehtiva edir. Onun asimmetrik oxşarlıq matrisindən çıxarıldığını vurğulamaq üçün matrisə '(a)' indeksini əlavə edirik. $n \times k$ ölçülü $Q_{(a),k}$ imbedinq matrisini yaratmaq məqsədilə $Q_{(a)}$ -nin ilk k sütunu çıxarılır. Bu matrisin i -ci sətri j -ci təpənin k -ölçülü imbedinqini ehtiva edir və Shi-Malik imbedinqi adlanır. Hazır klasterləşmə alqoritmlərindən hər hansı biri bu imbedinqə tətbiq oluna bilər. Biz bu imbedinqdəki ən üst məxsusi vektor haqqında bir müşahidə aparırıq ki, bu da stoxastik matrislər üçün Perron-Frobenius nəticəsində qeyd olunmuşdur (bax: Nəticə 10.4.2):

Xəssə 10.5.1 *Shi-Malik imbedinqindəki ən böyük məxsusi vektor 1-lərdən ibarət sütundur.* Bu xüsusi məxsusi vektor klasterləşmə nöqtəy-nəzərindən çox da məlumatverici deyil və bəzən kənarlaşdırılır (baxmayaraq ki, onun daxil edilməsi böyük bir fərq yaratmır).

10.5.1.1 Shi-Malik və Ng-Jordan-Weiss imbedinqlərinin əlaqələndirilməsi

Shi-Malik və Ng-Jordan-Weiss imbedinqləri demək olar ki, eynidir – əslində, sadə post-əməli mərhələsi vasitəsilə bu imbedinqlərdən birini digərindən əldə etmək mümkündür. Bu ona görədir ki, simmetrik normallaşdırılmış S matrisi və keçid matrisi $S = \Delta^{1/2} P \Delta^{-1/2}$ şəklində əlaqədardır, bu da həmin matrisləri oxşar edir. Buna görə də onların məxsusi qiymətləri eynidir, məxsusi vektorları isə bir-biri ilə əlaqəlidir.

Lemma 10.5.1 Tutaq ki, Δ qonşuluq matrisi A -nın dərəcə matrisidir. Tutaq ki, S və P müvafiq olaraq A -nın simmetrik normallaşdırılmış və stoxastik keçid matrisləridir. Onda x , λ məxsusi qiyməti ilə P -nin məxsusi vektorudur o və yalnız o zaman ki, $\sqrt{\Delta} x$, λ məxsusi qiyməti ilə S -nin məxsusi vektorudur.

İsbat: Biz göstəririk ki, yuxarıdakı ifadələrin hər ikisi yalnız və yalnız $\bar{x}$, $A\bar{x} = \lambda\Delta\bar{x}$ şərtini ödəyən A -nın ümumiləşdirilmiş məxsusi vektoru olduqda doğrudur.

Birincisi, qeyd edək ki, $P\bar{x} = \lambda\bar{x}$ ifadəsi yalnız və yalnız $\Delta^{-1}A\bar{x} = \lambda\bar{x}$ olduqda doğrudur, bu da $A\bar{x} = \lambda\Delta\bar{x}$ deməklə eynidir.

İkincisi, qeyd edək ki, $S[\sqrt{\Delta}\bar{x}] = \lambda[\sqrt{\Delta}\bar{x}]$ ifadəsi yalnız və yalnız $\Delta^{-1/2}A\bar{x} = \lambda[\sqrt{\Delta}\bar{x}]$, olduqda doğrudur, bu da $A\bar{x} = \lambda\Delta\bar{x}$ deməklə eynidir. Bununla da isbat başa çatır.

Shi-Malik imbedinqinin birinci məxsusi vektoru 1-lərdən ibarət sütun olduğu üçün buradan belə çıxır ki, Ng-Jordan-Weiss imbedinqinin birinci məxsusi vektoru $\sqrt{\Delta}[1, 1, \dots, 1]^T$ ilə mütenasibdir, bu da $[\sqrt{\delta_1}, \sqrt{\delta_2}, \dots, \sqrt{\delta_n}]^T$ vektoruna bərabərdir.

Nəticə 10.5.1 *Simmetrik normallaşdırılmış qonşuluq matrisi $S = \Delta^{-1/2}A\Delta^{-1/2}$ -in birinci məxsusi vektoru çəkili təpə dərəcələrinin kvadrat köklərini ehtiva edən n -ölçülü vektora mütenasibdir.*

Vacib bir məqam odur ki, Ng-Jordan-Weiss imbedinqi k -means alqoritmini tətbiq etməzdən əvvəl sətirləri normallaşdırır, Shi-Malik yanaşması isə k -means-i tətbiq etməzdən əvvəl sətirləri normallaşdırmır. Başqa sözlə, birincidə k -means tətbiq edilməzdən əvvəl *sətirlər normallaşdırılır*, ikincidə isə *sütunlar normallaşdırılır*. Bu, $S = \Delta^{-1/2}A\Delta^{-1/2}$ simmetrik nüvə matrisindən istifadə etməklə hər iki imbedinqin aşağıdakı vahid şəkildə çıxarılmasını nəzərdə tutur:

Lemma 10.5.2 *Tutaq ki, R sütunlarında simmetrik $S = \Delta^{-1/2}A\Delta^{-1/2}$ matrisinin ilk k (vahid normallaşdırılmış) məxsusi vektorlarını ehtiva edən $n \times k$ ölçülü matrisdir. Onda həm Shi-Malik, həm də Ng-Jordan-Weiss imbedinqləri aşağıdakı post-əməl mərhələləri vasitəsilə R -dən əldə edilə bilər:*

- Ng-Jordan-Weiss imbedinqi $n \times k$ ölçülü R matrisinin hər bir sətirini vahid normaya qədər normallaşdırmaqla əldə edilir.
- Shi-Malik imbedinqi $n \times k$ ölçülü $\Delta^{-1/2}R$ matrisinin hər bir sütununu vahid normaya qədər normallaşdırmaqla əldə edilir.

Bu müşahidə göstərir ki, hər iki üsul bir-birinə çox bənzəyir və yalnız eyni matrisin sətirlərinin/sütunlarının miqyaslanması və ya normallaşdırılması üzrə kiçik post-əməl mərhələləri ilə fərqlənir.

10.5.2 Spektral klasterləşməyə Laplasian yanaşması

Spektral klasterləşmənin Laplasian görünüşü onu əksər dərslərdə və icmal məqalələrində təqdim etməyin ən populyar üsuludur [84]. Biz spektral klasterləşmənin bu təqdimatını əsas

üsul kimi seçməmişik, çünki onun nüvə metodları ilə əlaqəsi daha fundamental təbiətə malikdir. Buna baxmayaraq, biz Laplasian yanaşmasını qısaca təqdim edəcək və onun nüvə yanaşması ilə əlaqəsini müzakirə edəcəyik. Laplasian yanaşmasının əlavə töhfəsi (nüvə yanaşmasından əlavə olaraq) alqoritmin normallaşdırılmamış variantını təmin etməsidir (baxmayaraq ki, o, çox nadir hallarda istifadə olunur).

10.5.2.1 Qraf Laplasianı

Tutaq ki, A istiqamətlənməmiş qrafın qonşuluq matrisi, Δ isə onun dərəcə matrisidir. P və S işarələri müvafiq olaraq stoxastik keçid matrisinə və simmetrik normallaşdırılmış qonşuluq matrisinə uyğundur. Aşağıdakı tərifləri istiqamətləndirilmiş qraflara asanlıqla şamil etmək mümkün olsa da, Laplasian matrisi demək olar ki, həmişə istiqamətlənməmiş qraf tətbiqlərində istifadə olunur. Qraf tətbiqlərində ümumi istifadə olunan Laplasianın üç növü mövcuddur. Birincisi, normallaşdırılmamış Laplasian L -dir:

$$L = \Delta - A \quad (10.4)$$

İstiqamətlənməmiş qrafın Laplasianı simmetrikdir, çünki həm Δ , həm də A simmetrikdir. Laplasian həmişə məxsusi (singulyar) matrisdir, çünki hər bir sətirin elementlərinin cəmi 0-a bərabərdir. Buna görə də Laplasianın məxsusi qiymətlərindən biri 0-dır.

Asimmetrik normallaşdırılmış Laplasian L_a yuxarıda təqdim olunan L matrisinə birtərəfli normallaşdırma tətbiq edir:

$$L_a = \Delta^{-1} L = \Delta^{-1} (\Delta - A) = I - P \quad (10.5)$$

Burada P əvvəlcə təqdim edilmiş $P = \Delta^{-1} A$ stoxastik keçid matrisidir. Buna görə də, asimmetrik normallaşdırılmış Laplasian stoxastik keçid matrisi P ilə sıx bağlıdır. Bu Laplasian simmetrik deyil, çünki P simmetrik deyil. Simmetrik normallaşdırılmış Laplasian L_s də oxşar şəkildə təyin edilir, sadəcə olaraq L -ə ikitərəfli normallaşdırma tətbiq olunur:

$$L_s = \Delta^{-1/2} L \Delta^{-1/2} = \Delta^{-1/2} (\Delta - A) \Delta^{-1/2} = I - S \quad (10.6)$$

Buna görə də, simmetrik normallaşdırılmış Laplasian simmetrik oxşarlıq matrisi S ilə sıx bağlıdır.

Qraf Laplasianının təpələrin çoxölçülü fəzada imbedinq edilməsi baxımından bəzi maraqlı yozumları mövcuddur. Ən sadə halda, hər bir i təpəsinin x_i həqiqi ədədinə imbedinq edildiyi

vəziyyəti nəzərdən keçirək. Buna görə də, $\bar{x}^T \bar{x} = 1$ olmaqla normallaşdırılmış $\bar{x} = [x_1 \dots x_n]^T$ vektorunu yaratmaq olar. İlk olaraq, 10.4 Tənliyinin normallaşdırılmamış q Laplasianını nəzərdən keçirək. Aşağıdakı nəticəni göstərmək olar:

Lemma 10.5.3 Əgər L istiqamətlənməmiş qonşuluq matrisinin normallaşdırılmamış Laplasianıdırsa, onda $\bar{x}^T L \bar{x}$ ifadəsi a_{ij} çəkisi ilə hər bir (x_i, x_j) cütünün kvadratik məsafələrinin çəkili cəminə mütənasibdir. Başqa sözlə, biz aşağıdakı ifadəyə maliklik:

$$\bar{x}^T L \bar{x} = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} (x_i - x_j)^2$$

İsbat: Bu nəticəni göstərmək üçün biz lemmada verilən tənliyin hər iki tərəfindəki ifadələri açsın və hər iki tərəfdəki hər bir həddin əmsalını nəzərdən keçirə bilərik. $i \neq j$ üçün göstərmək olar ki, $x_i x_j$ şəklindəki istənilən həddin əmsalı hər iki tərəfdə $-(a_{ij} + a_{ji})$ -ə bərabərdir. Digər

tərəfdən, istənilən i üçün göstərmək olar ki, x_i^2 həddinin əmsalı $\frac{1}{2} \sum_{j=1}^n (a_{ij} + a_{ji})$ -dir.

Yuxarıdakı nəticə əsasında bir sıra müşahidələr etmək mümkündür. Bu müşahidələr qraflar üzərində maşın öyrənməsi tətbiqlərində müxtəlif üsullarla istifadə olunur:

1. Dərhal gözə çarpan müşahidə odur ki, Lemma 10.5.3-ə əsasən, istənilən $\bar{x}$ üçün $\bar{x}^T L \bar{x}$ mənfi deyil. Buna görə də o, müsbət yarımüyyənəkdir.
2. Normallaşdırılmamış qraf Laplasianının müsbət yarımüyyən olması faktı simmetrik normallaşdırılmış qraf Laplasianına da asanlıqla şamil edilə bilər (bax: Məsələ 10.5.1). Müsbət yarımüyyənlik anlayışının yalnız simmetrik qraflar üçün təyin olunmasına baxmayaraq, onu da göstərmək olar ki, asimmetrik normallaşdırılmış qraf Laplasianı mənfi olmayan məxsusi qiymətlərə malikdir və bütün $\bar{x}$ -lər üçün $\bar{x}^T L_a \bar{x} \geq 0$ şərtini ödəyir. Başqa sözlə, o, asimmetrik qraflar üçün müsbət yarımüyyənliyin genişləndirilmiş anlayışını ödəyir. Laplasianların hər bir növü həmişə 0-a bərabər olan məxsusi qiymətə malikdir, çünki Laplasianlar ən azı 1 rəngli nüvə fəzasına (null space) malik məxsusi (singulyar) matrislərdir. Əgər qraf əlaqəlidirsə, nüvə fəzasının rəngi dəqiq 1-dir. Laplasianlar həmişə mənfi olmayan məxsusi qiymətlərə malik olduğundan, buradan belə çıxır ki, 0 ən kiçik məxsusi qiymətdir və əlaqəli qraflar üçün bu, yeganədir.
3. $\bar{x}^T L \bar{x}$ ifadəsini minimuma endirən vahid $\bar{x}$ vektorunun tapılması təpələrin 1-ölçülü imbedinqini təmin edir ki, nəticədə ağır a_{ij} çəkili (i, j) tilləri ilə birləşdirilmiş $[i, j]$ təpə cütleri $(x_i - x_j)^2$ qiymətinə görə bir-birinə yaxın olur. Bunu Lemma 10.5.3-dəki $\bar{x}^T L \bar{x}$ -in çəkili kvadratlar cəmi yozumundan asanlıqla çıxarmaq olar. Başqa sözlə, bu tip hədəf funksiyası klasterləşməyə uyğun gələn imbedinq tapır və məhz buna görə də o, spektral klasterləşmə üçün faydalıdır.

Aşağıdakı nəticəni Lemma 10.5.3-dən və determinantların bəzi xassələrindən istifadə etməklə nisbətən asanlıqla göstərmək olar.

Məsələ 10.5.1 Tutaq ki, L , $L_a \Delta^{-1} L$ və $L_s = \Delta^{-1/2} L \Delta^{-1/2}$ tillərində mənfi olmayan çəkili olan istiqamətlənməmiş qrafın normallaşdırılmamış, asimmetrik normallaşdırılmış və simmetrik normallaşdırılmış Laplasianlarıdır. Aşağıdakıları göstərin:

- (i) İstənilən $\bar{x}$ üçün $\bar{x}^T L_s \bar{x}$ ifadəsinin qiyməti həmişə mənfi deyil;
- (ii) L_s və L_a matrislərinin məxsusi qiymətləri eyni olmalıdır; və
- (iii) İstənilən $\bar{x}$ üçün $L_a \bar{x}$ ifadəsinin qiyməti həmişə mənfi deyil.

Spektral klasterləşmə üçün ümumi yanaşma aşağıdakı kimi işləyir:

1. L , L_a və L_s üç Laplasian matrisindən birini seçin. Laplasianın ən kiçik k məxsusi vektorunu tapın və sütunlarında bu məxsusi vektorları vahid normaya qədər miqyasladıqdan sonra ehtiva edən $n \times k$ ölçülü Q_k matrisini yaradın. Q_k -nin hər bir sətri təpənin k -ölçülü imbedinqinə uyğundur.
2. Əgər birinci addımda simmetrik Laplasian L_s seçilibsə, Q_k -nin hər bir sətrini vahid normaya qədər normallaşdırmaq üzrə əlavə addımı yerinə yetirin.
3. Müxtəlif təpələrin imbedinq təqdimatlarına k -means alqoritmini tətbiq edin.

Vacib bir məqam odur ki, biz oxşarlıq matrislərinin böyük məxsusi vektorlarından istifadə edirik, lakin Laplasianın kiçik məxsusi vektorlarından istifadə edirik. İkisi arasındakı əlaqəni nəzərə aldıqda, bu, təəccüblü deyil. Məsələn, simmetrik normallaşdırılmış qonşuluq matrisi S , simmetrik Laplasian L_s ilə $L_s = I - S$ şəklində əlaqədardır. Nəticədə, hər iki matrisin məxsusi vektorları eynidir və uyğun məxsusi qiymətlərin cəmi 1-ə bərabərdir. Biz bu nəticələri spektral klasterləşmənin nüvə yanaşması ilə Laplasian yanaşmasının ekvivalentliyi baxımından ümumiləşdiririk.

Lemma 10.5.4 (Nüvə və Laplasian yanaşmalarının ekvivalentliyi) Tutaq ki, A $n \times n$ ölçülü qonşuluq matrisidir, P onun stoxastik keçid matrisidir və S onun simmetrik normallaşdırılmış qonşuluq matrisidir. Tutaq ki, $L_a = I - P$ və $L_s = I - S$ müvafiq olaraq asimmetrik və simmetrik Laplasianlardır. Onda aşağıdakılar doğrudur:

- Stoxastik keçid matrisi P -nin **ən böyük** k məxsusi vektoru asimmetrik Laplasian L_a -nın **ən kiçik** k məxsusi vektoru ilə eynidir.
- Simmetrik normallaşdırılmış qonşuluq matrisi S -nin **ən böyük** k məxsusi vektoru simmetrik Laplasian L_s -in **ən kiçik** k məxsusi vektoru ilə eynidir.

İsbat: Biz nəticəni simmetrik Laplasian S halı üçün göstəririk. Asimmetrik Laplasian üçün isbat da oxşardır. İstənilən S matrisinin λ məxsusi qiymətinə malik məxsusi vektoru, həmçinin $I - S$ matrisinin $1 - \lambda$ məxsusi qiymətinə malik məxsusi vektorudur. Bunun səbəbi odur ki, $S\bar{x} = \lambda\bar{x}$ o zaman və yalnız o zaman doğrudur ki, $(I - S)x = (1 - \lambda)x$ doğru olsun. Buna görə də, S -in böyük məxsusi vektorları $L^{(s)} = (I - S)$ matrisinin kiçik məxsusi vektorlarına uyğun gəlir.

Diqqətəlayiqdir ki, normallaşdırılmamış L Laplasianının kiçik məxsusi vektorları qonşuluq matrisi A -nın böyük məxsusi vektorları ilə tam olaraq eyni deyil. Hər halda, normallaşdırılmamış variantların istifadəsi əksər praktiki tətbiqlərdə nisbətən nadir hallarda rast gəlinir.

10.5.2.2 Laplasian ilə Optimizasiya Modeli

Laplasianın kiçik məxsusi vektorlarının imbedinq üçün istifadə edilməsi faktı həm də Laplasianı əhatə edən optimizasiya modelindən istifadə etməklə çıxarıla bilər. Əslində, bu yanaşma əksər dərslərin və icmalların populyar təqdimat üsuludur [84]. Biz Lemma

10.5.3-dəki nəticəni xatırladıyıq ki, buna əsasən $\bar{x}^T L \bar{x}$ ifadəsi verilənlər nöqtələri cütləri arasındakı kvadratik məsafələrin çəkili cəmini təmin edir:

$$\bar{x}^T L \bar{x} = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} (x_i - x_j)^2$$

Burada x , hər bir təpə üçün bir koordinat ehtiva edən n -ölçülü vektordur. Nəzərə alın ki, k ədəd $x_1, \dots, x_k$ vektorundan istifadə etməklə bu nəticəni hər bir təpənin k -ölçülü imbedinqinə asanlıqla şamil etmək olar. Bu halda, n -ölçülü x_i vektoru n müxtəlif təpənin i -ci koordinatını ehtiva edir. Belə bir halda, $x_i^T L x_i$ -nin k müxtəlif qiyməti üzrə cəmi imbedinq üçün Evklid məsafələrinin kvadratlarının çəkili cəmini təmin edir. Buna görə də, klasterləşməyə uyğun gələn imbedinq aşağıdakı optimizasiya modeli ilə təyin oluna bilər:

$$\sum_{i=1}^k \bar{x}^T L \bar{x}_i$$

$$\|\bar{x}_i\|^2 = 1 \quad \forall i \in \{1 \dots k\}$$

$\bar{x}_1 \dots \bar{x}_k$ qarşılıqlı ortoqonaldır.

Bu optimizasiya modeli hər bir təpənin k -ölçülü imbedinqini tapmağa çalışır ki, nəticədə Evklid məsafələrinin kvadratlarının çəkili cəmi minimuma enmiş olsun. Yuxarıdakı model 3-cü Fəslin 3.4.5-ci bölməsində müzakirə olunan norma məhdudiyyətli optimizasiya məsələsinin xüsusi halıdır. 3.4.5-ci bölmədə müzakirə olunduğu kimi, L -in ən kiçik k məxsusi vektoru bu optimizasiya məsələsinin həllini təmin edir. Nəzərə alın ki, yuxarıdakı modeldə L -i $L^{(s)}$ ilə əvəz etməklə tamamilə eyni modeli simmetrik normallaşdırılmış Laplasian üçün də istifadə etmək olar. Asimmetrik Laplasianın halı isə bir qədər fərqlidir, çünki məsələ aşağıdakılara gəlib çıxır:

$$\sum_{i=1}^k \bar{x}^T L \bar{x}_i$$

$\bar{x}_1 \dots \bar{x}_k \Delta$ –ortoqonaldır.

Orijinal optimizasiya məsələsindən yeganə fərq odur ki, vektorlar Δ -ortonormaldır. Δ -ortonormallıq anlayışı aşağıdakı kimi təyin edilir:

matric elave edeceksen

Δ -ortonormallığın tətbiqi yüksək dərəcəli təpələrin təsirini zəiflədir. Göstərmək olar ki, optimal həll $\Delta^{-1} L$ -in ən kiçik k məxsusi vektorudur. Bu nəticənin isbatını praktiki tapşırıq olaraq saxlayırıq.

Məsələ 10.5.2 Göstərin ki, asimmetrik spektral klasterləşmənin optimizasiya modelinin optimal həlli $L_a = \Delta^{-1}L$ matrisinin ən kiçik məxsusi vektoruna uyğun gəlir.

Yuxarıdakı məsələdə əsas ipucu dəyişənlərin çevrilməsindən (variable transformation)

istifadə etməkdir ki, burada hər bir $\bar{x}_i = \sum_{j=1}^n \beta_{ij} \bar{p}_j$ ifadəsi $\Delta^{-1}L$ -in vahid məxsusi vektorlarının

bazis sistemi vasitəsilə xətti kombinasiya kimi göstərilir. Sonrakı mərhələdə hədəf funksiyası və məhdudiyyətlər bu əmsal dəyişənləri vasitəsilə çevrilərkən β_{ij} əmsalları tapılmalıdır.

Göstərin ki, $\bar{p}_1 \dots \bar{p}_n$ məxsusi vektorları Δ -ortoqonaldır və bundan istifadə edərək hədəf funksiyasını β_{ij} -nin müxtəlif qiymətləri baxımından sadələşdirin. Göstərmək olar ki, β_{ij} -nin

bütün qiymətləri ya $1/\sqrt{\Delta}$, ya da 0 olacaqdır.

10.5.3 Spektral Klasterləşmənin Matris Faktorizasiyası Görünüşü

Spektral klasterləşmə matris faktorizasiyasının bir formasıdır. Həm asimmetrik, həm də simmetrik spektral klasterləşmələr aşağıdakı faktorizasiyalardan istifadə etməklə əldə edilir:

elave dustur var

Başqa sözlə, hər iki faktorizasiya UV^T şəklində ifadə edilə bilər. Biz həmçinin Fəsil 8-in gradient enməsi (gradient-descent) üsullarından istifadə etməklə S və ya P matrisini təxmini olaraq UV^T şəklində faktorizasiya edə bilərik.

Nəzərə alın ki, həm U , həm də V matrisləri $n \times k$ ölçülüdür, burada k faktorizasiyanın rəngidir. Sonradan hər bir təpənin $2k$ -ölçülü imbedinq təqdimatlarını yaratmaq üçün U və V -nin k -ölçülü sətirlərini birləşdirmək olar. Nəticə spektral klasterləşmənin nəticəsi ilə tamamilə eyni olmayacaq, lakin bu ümumi yanaşma çox vaxt spektral klasterləşməyə bənzər nəticələr verəcəkdir. Bu ümumi baxış spektral klasterləşmənin birbaşa tətbiqinin mümkün olmadığı hallarda faydalıdır. Məsələn, istiqamətlənmiş qraflar halında, qonşuluq matrisi həqiqi qiymətli məxsusi vektorlar və məxsusi qiymətlərlə diaqonallaşdırıla bilməyə bilər. Belə hallarda biz istiqamətlənmiş qraf üzərində faktorizasiyanın ümumiləşdirilmiş formalarından istifadə edə bilərik.

Tutaq ki, A istiqamətlənmiş qrafın qonşuluq matrisidir. İstiqamətlənməmiş qonşuluq matrislərində olduğu kimi, zəif əlaqələr yalnız öz uclarındakı iki təpənin həm ən yüksək k daxil olan, həm də ən yüksək k xaric olan tilləri arasında olan tilləri saxlamaqla silinir. Nəzərə alın ki, matris nə zəif əlaqələrin silinməsindən əvvəl, nə də sonra simmetrik olmayacaq (çünki qraf onsuz da istiqamətlənmişdir). Tutaq ki, δ_i^{in} i -ci təpənin çəkili daxilolma dərəcəsidir (weighted indegree) və o, A -nın i -ci sütununun elementlərini (qeyri-binar ola bilər) toplamaqla əldə edilir. Eynilə, tutaq ki, δ_i^{out} i -ci təpənin çəkili xaricolma dərəcəsidir (weighted outdegree) və o, A -dakı qiymətləri i -ci sətir üzrə toplamaqla əldə edilir. Diaqonal elementləri müvafiq olaraq δ_i^{in} və δ_i^{out} olan uyğun $n \times n$ ölçülü Δ_{in} və Δ_{out} diaqonal matrisləri yaratmaq

olar. Onda hər bir (i, j) tili i -dəki xaricolma dərəcəsinin və j -dəki daxilolma dərəcəsinin həndəsi ortasından istifadə etməklə normallaşdırılır:

$$a_{ij} \leftarrow \frac{a_{ij}}{\sqrt{\delta_i^{out}} \sqrt{\delta_j^{in}}}$$

Bu əlaqəni normallaşdırılmış $\$N\$$ matrisinin köməyi ilə matris formasında da yazmaq olar:

$$N = \Delta_{out}^{-1/2} A \Delta_{in}^{-1/2}$$

N matrisi hesablandıqdan sonra, biz onu Fəsil 8-də müzakirə olunan üsulların hər hansı birindən istifadə edərək $N \approx UV^T$ şəklində faktorizasiya edə bilərik. Burada U və V ölçüləri $n \times k$ olan matrislərdir, k isə faktorizasiyanın rəngidir. U -nun j -ci sətiri i -ci təpənin xaricə gedən faktorunu (və ya göndərən faktorunu - sender factor) təmin edir və növbəti bölmədə müzakirə olunacaq mərkəzilik ölçülərinin bəziləri ilə əlaqədardır. V -nin i -ci sətiri isə i -ci təpənin daxil olan faktorunu (və ya qəbul edən faktorunu - receiver factor) təmin edir. Hər bir təpənin $2k$ -ölçülü təqdimatını yaratmaq üçün bu təqdimatları birləşdirmək (concatenate etmək) olar. Nəticə etibarilə, bu təqdimat klasterləşmə üçün istifadə oluna bilər.

10.5.3.1 Maşın Öyrənməsi Tətbiqi: İstiqamətlənmiş Əlaqə Proqnozu (Directed Link Prediction)

Yuxarıda qeyd olunan yanaşmadan istiqamətlənmiş əlaqə proqnozu üçün istifadə etmək olar. Belə bir yanaşma Twitter kimi istiqamətlənmiş izləyici-izlənən şəbəkələrində əlaqələrin proqnozlaşdırılması üçün faydalı ola bilər. Normallaşdırılmış N matrisi $N \approx UV^T$ şəklində faktorizasiya edildikdən sonra, UV^T bərpası qonşuluq matrisinin istiqamətlənmiş əlaqələrini proqnozlaşdırır. Adətən, istiqamətlənməmiş qraflarda əlaqə proqnozuna ehtiyac duyulsa da, bəzi tətbiqlər istiqamətlənmiş qraflarda da əlaqələrin proqnozlaşdırılmasını tələb edə bilər. Qeyd etmək vacibdir ki, UV^T -dəki (i, j) elementləri UV^T -dəki (i, j) elementləri ilə eyni olmaya bilər. Başqa sözlə, əlaqələrin proqnozu istiqamətə həssasdır. Axı yeniyetmənin Twitter-də məşhur rok ulduzunu izləmə ehtimalı ilə rok ulduzunun yeniyetməni izləmə ehtimalı eyni deyil.

10.5.4 Spektral Klasterləşmənin Hansı Görünüşü Daha Məlumatvericidir?

Bu bölmə spektral klasterləşmənin bir neçə fərqli təqdimatını təqdim edir. Aşağıda biz spektral klasterləşmənin bu müxtəlif baxışlarına daha geniş perspektiv təqdim edirik:

1. **Qonşuluq matrisləri ilə nüvə baxışı:** Spektral klasterləşmənin normallaşdırılmış variantları açıq xüsusiyyət mühəndisliyi ilə oxşarlığa əsaslanan klasterləşmə üsullarının xüsusi halları kimi nəzərdən keçirilə bilər (bax: Fəsil 9, Bölmə 9.5.1.1). Spektral klasterləşmə ilə bu üsullar ailəsi arasındakı əsas fərq yalnız zəif əlaqələrin

silinməsi məqsədilə matrisin əvvəlcədən necə emal edilməsidir. Nüvə baxışının əsas üstünlüyü odur ki, o, Fəsil 9-da indiyə qədər rastlaşdığımız digər bütün nüvə üsulları ilə vahid yanaşma təmin edir. Spektral üsul sadəcə olaraq kernel k-means kimi geniş nüvə üsulları ailəsinin bərabərhüquqlu üzvüdür — nə artıq, nə də əskik. Əsas fərqləndirici xüsusiyyət oxşarlıq matrisinin heuristik seyrəltilməsi/normallaşdırılması və mühəndislik nəticəsində əldə edilmiş xüsusiyyətlərin normallaşdırılmasıdır (ağardılması).

2. **Laplasian baxışı:** Laplasianın istifadəsi spektral klasterləşmənin populyar izahatlarında üstünlük təşkil edən yanaşmadır [84]. Bu yanaşmanın xarakterinin nüvə və ya faktorizasiya üsullarından fərqli olması səbəbindən, spektral klasterləşmə digər əlaqəli imbedinq üsullarından çox fərqli şəkildə qəbul edilir. Laplasian baxışı çox vaxt normallaşdırılmış qrafda minimum kəsiklərin tapılmasının zərif *diskret* optimizasiya məsələsi kimi şərh olunur [115]. Lakin spektral klasterləşmənin faktiki optimizasiya məsələsi bu məsələnin yalnız *kəsilməz yaxınlaşmasıdır* ki, bu da diskret versiyanın istənilən dərəcədə zəif yaxınlaşması ola bilər.
3. **Matris faktorizasiyası baxışı və onun genişləndirilmələri:** Spektral klasterləşmənin asimmetrik formaları matris faktorizasiyası kontekstində nəzərdən keçirilə bilər. Ən əsası odur ki, bu baxış bucağı *istiqamətlənmiş* qrafların klasterləşdirilməsi yanaşmasının ümumiləşdirilməsini təmin edir ki, bu da spektral klasterləşmənin adi (vanilla) versiyası ilə mümkün deyil.

Hər hansı bir üsulu yaxşı başa düşməyin vacib prinsiplərindən biri onun digər oxşar üsullarla əlaqəsini anlamaqdır. Bu cür dərk etmə faydalı genişləndirmələri və tətbiqləri təşviq edir. Spektral klasterləşmə *açıq xüsusiyyət mühəndisliyinə və verilənlərdən asılı nüvəyə malik nüvə klasterləşmə üsulunun sadəcə xüsusi halıdır*. Xüsusiyyətlər üzərində k-means tətbiq etməzdən əvvəl nüvədən çıxarılmış xüsusiyyətlərin sonrakı emalına ehtiyac duyduğundan, o, nüvə fəndi (kernel trick) ilə birlikdə (məsələn, kernel k-means kimi) istifadə oluna bilməz.

10.6 Qraf Matrislərinin Sol Məxsusi Vektorları

Əvvəlki bölmədə müzakirə edildiyi kimi, qonşuluq matrisi A -nın stoxastik keçid matrisinin sağ məxsusi vektorları klasterləşmə üçün Shi-Malik imbedinqini yaratmaq məqsədilə istifadə olunur. Bu bölmədə biz stoxastik keçid matrisinin sol məxsusi vektorlarını araşdıracağıq. Bununla belə, əvvəlki bölmədəki izahatdan bir neçə fərq var. Birincisi, biz Perron-Frobenius teoreminə əsasən 1 məxsusi qiymətinə malik olan yalnız əsas (yəni ən böyük) məxsusi vektorun xüsusiyyətlərini araşdıracağıq. İkincisi, biz klasterləşmədən daha çox Vebin qraf strukturu ilə əlaqəli tətbiqləri araşdıracağımız üçün diqqət istiqamətlənməmiş qraflardan deyil, istiqamətlənmiş qraflardan olacaqdır. Axı, veb sahifəsinin keçid strukturu simmetrik deyil. Nəhayət, əvvəlki bölmədə müzakirə olunan klasterləşmə tətbiqi zəif əlaqələri aradan qaldırmaq məqsədilə həmişə qonşuluq matrisini dəyişdirir. Bu dəyişiklik bu bölmədə müzakirə olunan tətbiqlər üçün edilmir. Əksinə, istiqamətlənmiş qrafı güclü bağlı etməyə yönəlmiş fərqli bir dəyişiklik növündən istifadə olunur.

Veb kimi bir çox tətbiqlərdə yüksək nüfuz səviyyəsinə malik təpələr axtarılır. İntuitiv olaraq, əgər bir çox veb-səhifə ona istinad edirsə, veb-səhifə yüksək *nüfuz* səviyyəsinə malikdir. Bununla belə, sadəcə olaraq səhifəyə istinad edən veb-səhifələrin sayından istifadə etmək onun nüfuzunun yanıltıcı göstəricisi ola bilər, çünki ona istinad edən səhifələrin özləri aşağı

keyfiyyətli ola bilər. Buna görə də, adətən digər yüksək nüfuzlu səhifələr tərəfindən istinad edilən səhifələri aşkar etmək istənilir. Qrafda *təsadüfi gəzintilər* (random walks) anlayışından istifadə etməklə bu cür rekursiv əlaqəni modelləşdirmək olar.

Qonşuluq matrisi A , çəkili dərəcə matrisi Δ və stoxastik keçid matrisi $P = \Delta^{-1}A$ olan istiqamətlənmiş qrafı təsvir edək. P -dəki hər bir p_{ij} elementini, səyyahın keçid ehtimalları vektorundan $[p_{i1}, p_{i2}, \dots, p_{in}]$ istifadə edərək i -dən çıxan təpələri seçməsi fərziyyəsi altında, təsadüfi səyyahın i Veb səhifəsindən j Veb səhifəsinə keçid ehtimalı kimi şərh etmək olar. Nəzərə alın ki, bu keçid ehtimallarının cəmi 1-ə bərabərdir. Təpənin (Veb səhifənin) *PageRank*-ə əsaslanan nüfuzu təsadüfi səyyahın həmin təpəyə (Veb səhifəyə) baş çəkməsinin stasionar hal ehtimalı kimi təyin edilir. Maraqlıdır ki, bizim indicə təsvir etdiyimiz proses məhz Markov zəncirinin keçid prosesidir. Markov zənciri bir sıra vəziyyətlərdən (təpələrdən) və onların arasındakı bir sıra keçidlərdən (ehtimalı tillərdən) ibarətdir. Buna görə də, Markov zənciri bu bölmədə təqdim olunan qraf strukturları vasitəsilə mükəmməl şəkildə təsvir olunur. Bundan əlavə, Markov zəncirinin stasionar hal ehtimallarını onun keçid matrisinin məxsusi vektorları vasitəsilə tapmaq üçün dəqiq müəyyən edilmiş proseduru mövcuddur.

Yaranan suallardan biri Markov zəncirinin təsadüfi səyyahın başlanğıc təpəsindən asılı olmayan stasionar hal ehtimallarına malik olduğu şərtlərlə bağlıdır. Belə Markov zəncirləri erqodik adlanır və onlar aşağıdakı şərti ödəməlidirlər:

Tərif 10.6.1 (Erqodik Markov Zənciri) *Əgər keçid matrisi güclü bağlıdırsa, Markov zənciri erqodik kimi təyin edilir.*

Güclü bağlı olmayan qraflar gəzintinin başlanğıc nöqtəsindən asılı olan stasionar hal ehtimallarına malik ola bilər. Məsələn, güclü bağlı olmayan Şəkil 10.5(b)-dəki istiqamətlənmiş qrafı nəzərdən keçirək. Bu halda, təsadüfi gəzintiyə 1 nömrəli təpədən başlamaq yalnız $A1$ komponentindəki təpələr arasında paylanan stasionar hal ehtimalları ilə nəticələnəcəkdir. Bununla belə, gəzintiyə 6 nömrəli təpədən başlamaq $A1$ və ya $A2$ komponentlərindən hər hansı birinə gətirib çıxara bilər.

Bu tələb səbəbindən dərhal yaranan problem odur ki, bir çox real tətbiqlər güclü bağlı olan istiqamətlənmiş qraflarla nəticələnir. Məsələn, Veb şübhəsiz ki, güclü bağlı olan istiqamətlənmiş qraf deyil. Yeni Veb-sayt qurarkən, ehtimal ki, siz bir çox digər Veb-saytlara istinad edə bilərsiniz, lakin heç kim sizin Veb-saytınızı tanımaya bilər və ya ona istinad etməyə bilər. Bu, stasionar hal ehtimallarının hesablanması baxımından problem ola bilər.

Bu problem yenidənbaşlama ehtimallarının (restart probabilities) istifadəsi ilə həll edilir. Hər bir addımda təsadüfi səyyaha $\alpha < 1$ ehtimalı ilə şəbəkədəki tamamilə təsadüfi bir təpəyə sıfırlanmağa (yenidən başlamağa) və $(1 - \alpha)$ ehtimalı ilə təsadüfi gəzintiyə davam etməyə icazə verilir. α -nın qiyməti tətbiqə xas şəkildə seçilən hiper-parametredir. Keçid matrisi P köhnə keçid matrisi P_o -dan aşağıdakı kimi əldə edilir:

$$P \leftarrow (1 - \alpha)P_o + \alpha M/n$$

Burada M hamısı 1-lərdən ibarət olan $n \times n$ ölçülü matrisdir. M/n matrisi elə bir keçid matrisidir ki, onda $1/n$ ehtimalı ilə istənilən təpədən digərinə keçmək mümkündür. Buna görə

də, bu, güclü bağlı yenidənbaşlama matrisidir. Sonuncu P keçid matrisi orijinal keçid matrisinin və yenidənbaşlama matrisinin çəkili kombinasiyasıdır. Bundan sonra biz həmişə keçid matrisinin güclü bağlı olduğunu və yenidənbaşlama matrisinin ilkin emal mərhələsi kimi daxil edildiyini güman edəcəyik.

10.6.1 Keçid Matrisinin Sol Məxsusi Vektoru Kimi PageRank

Tutaq ki, π_i təsadüfi gəzinti modeli altında i təpəsinin stasionar hal ehtimalıdır. Onda müəyyən bir i təpəsinə baş çəkmə ehtimalı π_i , həmin təpəyə onun daxil olan hər bir təpəsindən keçid ehtimallarının cəmi ilə verilir. j təpəsindən i təpəsinə keçid ehtimalı $\pi_i p_{ji}$ ilə verilir. Biz bu əlaqəni hər bir $i \in \{1, \dots, n\}$ təpəsi üçün riyazi olaraq aşağıdakı kimi yazmaqla bilirik:

$$\pi_i = \sum_{j=1}^n \pi_j p_{ji} \quad \forall i \in \{1, \dots, n\}$$

Nəzərə alın ki, n dəyişəndə $\pi_1, \dots, \pi_n$ \$n\$ dənə tənliyimiz var. n dəyişəndən ibarət vektoru $\bar{\pi} = [\pi_1, \pi_2, \dots, \pi_n]^T$ kimi işarə edə bilirik. Onda yuxarıdakı tənliklər sistemini vektor formasında aşağıdakı kimi yazmaq olar:

$$\bar{\pi}^T = \bar{\pi}^T P$$

Bu, məhz 1 məxsusi qiymətində sol məxsusi vektor tənliyidir. Perron-Frobenius teoremindən biz artıq bilir ki, güclü bağlı qraflarla əlaqəli stoxastik keçid matrisləri üçün 1 məxsusi qiymətinə malik yeganə məxsusi vektor mövcuddur.

$\bar{\pi}$ -ni tapmaq üçün qüvvət üsulundan (bax: Fəsil 3, Bölmə 3.5.2) istifadə etmək olar, çünki o, stoxastik keçid matrisinin əsas məxsusi vektorudur. Bu yanaşma $\bar{\pi}$ -ni 0 ilə 1 arasında təsadüfi müsbət qiymətlərdən ibarət vektor kimi ilkinləşdirməklə, və daha sonra bütün qiymətləri cəmi 1 olacaq şəkildə miqyaslamaqla işləyir. Növbəti mərhələdə aşağıdakı iterativ proses təkrar olunur:

$$1. \quad \bar{\pi}^T \leftarrow \bar{\pi}^T P$$

2. $\bar{\pi}$ -nin elementlərinin cəmi 1 olacaq şəkildə onu normallaşdırın.

Bu yanaşma yığılma (convergence) əldə olunana qədər tətbiq edilir.

Məsələ 10.6.1 (Səmərali Hesablama) *Yenidənbaşlamanın istifadəsi ilə bağlı problemlərdən biri odur ki, əsas qraf seyrək olsa belə, o, keçid matrisi P -ni sıx (dense) edir. Yalnız seyrək matris əməliyyatlarından istifadə etməklə $\bar{\pi}$ -ni hesablamağa bilmək üçün P -nin yenidənbaşlama komponentinə daha diqqətli necə yanaşma biləcəyinizi müzakirə edin.*

Yuxarıdakı məsələni həll etmək üçün ipucu odur ki, sonuncu keçid matrisi orijinal P_o keçid matrisi vasitəsilə $(1 - \alpha)P_o + \alpha \bar{1}_n \bar{1}_n^T / n$ kimi təqdim edilə bilər. Burada $\bar{1}_n$ elementləri 1-lərdən ibarət n -ölçülü sütun vektorudur.

10.6.2 Nüfuz və Mərkəziliyin Əlaqəli Ölçüləri

PageRank alqoritmi hər bir istiqamətlənməmiş tili əks istiqamətlərdə olan iki istiqamətlənmiş tillə əvəz etməklə istiqamətlənməmiş şəbəkələrə asanlıqla tətbiq edilə bilər. İstiqamətlənmiş şəbəkələrə tətbiq edildikdə *PageRank* nüfuz ölçüsü, istiqamətlənməmiş şəbəkələrə tətbiq edildikdə isə mərkəzilik ölçüsüdür. Nüfuz vacibliyin asimmetrik ölçüsünü hesablayır və bir təpəyə digər təpələrdən əlçatan olduqda yüksək olur. Bununla belə, əgər bir təpə bir çox təpəyə istinad edirsə, lakin çox az təpədən əlçatandırsa, onun *PageRank*-i olduqca aşağı ola bilər. İstiqamətlənməmiş şəbəkələrin simmetrik təbiətinə görə daxil olan və xaric olan əlçatanlığı fərqləndirmək mümkün deyil. Buna görə də o, mərkəzilik ölçüsü hesab olunur. *PageRank* şəbəkələrdə mərkəzilik və nüfuzun hesablanması üçün istifadə olunan bir çox mexanizmlərdən yalnız biridir. Bunların arasında stoxastik keçid matrisindən fərqli olaraq, qonşuluq matrisinin əsas sol məxsusi vektorundan istifadə edən məxsusi vektor mərkəziliyi birincidir:

Tərif 10.6.2 Məxsusi Vektor Mərkəziliyi Tutaq ki, A istiqamətlənməmiş qrafın $n \times n$ ölçülü qonşuluq matrisidir. Onda əsas sol məxsusi vektorun n komponenti təpələrin məxsusi vektor mərkəziliyini müəyyən edir. Başqa sözlə, n təpənin hər birinin məxsusi vektor mərkəziliyi $\pi^T A = \lambda \pi^T$ -ölçülü vektorunda yerləşir. Burada λ matrisin ən böyük məxsusi qiymətidir.

Perron-Frobenius teoreminə əsasən, ən böyük məxsusi qiymət matrisin maksimum və orta dərəcəsi arasında yerləşir. *PageRank* kimi, məxsusi vektor mərkəziliyi də qüvvət üsulundan istifadə etməklə hesablanı bilər. İstiqamətlənmiş qraflar üçün məxsusi vektor nüfuzu anlayışını da hesablamaq mümkündür.

Tərif 10.6.3 Məxsusi Vektor Nüfuzu Tutaq ki, A istiqamətlənmiş qrafın $n \times n$ ölçülü qonşuluq matrisidir. Onda əsas sol məxsusi vektorun n komponenti təpələrin məxsusi vektor nüfuzunu müəyyən edir. Başqa sözlə, n təpənin hər birinin məxsusi vektor nüfuzu $\pi^T A = \lambda \pi^T$ -ölçülü vektorunda yerləşir. Burada λ matrisin ən böyük məxsusi qiymətidir.

PageRank halında olduğu kimi, əgər qraf güclü bağlı deyilsə, ən böyük məxsusi vektor yeganə olmaya bilər. Buna görə də, matrisi güclü bağlı etmək üçün onu M/n yenidənbaşlama matrisi ilə (orta qiymət şəklində) uyğunlaşdırmaq lazımdır. Burada M hamısı 1-lərdən ibarət matrisdir. *PageRank*-də olduğu kimi, bu ortaqlama α hamarlama parametri ilə çəkili şəkildə həyata keçirilir.

Nəhayət, simmetrik normallaşdırılmış matrislərin sol məxsusi vektorlarını araşdırmaq maraqlıdır. Tutaq ki, A istiqamətlənməmiş şəbəkənin qonşuluq matrisidir və Δ i -ci diaqonal elementi δ_i dərəcəsi olan çəkili dərəcə matrisidir. Onda simmetrik normallaşdırılmış matris aşağıdakı kimi verilir:

$$S = \Delta^{-1/2} A \Delta^{-1/2}$$

S matrisi simmetrik olduğundan, onun sol və sağ məxsusi vektorları eynidir. Bu matrisin əsas məxsusi vektoru təpə dərəcələrinin kvadrat köklərini ehtiva edir. Bu nəticə Corollary 10.5.1-də verilmişdir. Təpənin dərəcəsi onun dərəcə mərkəziliyidir.

Dərəcə mərkəziliyi qonşuluq matrisindən sadə şəkildə hesablanırsa bildiyi üçün məxsusi vektor hesablamasından istifadə etməyin mənası yoxdur. Buna baxmayaraq, bütün məxsusi vektorların hansısa formada mərkəzilik ölçüləri ilə əlaqəli olması maraqlıdır. *Dərəcə nüfuzunun (degree prestige)* uyğun anlayışı istiqamətlənmiş qrafda hər bir təpənin daxil olan dərəcəsi (indegree) ilə təyin edilir. Praktiki olaraq faydalı olmasa da, diqqətli normallaşdırmadan sonra dərəcə nüfuzunu qonşuluq matrisinin məxsusi vektorları ilə əlaqələndirmək mümkündür. Vacibdir ki, normallaşdırma xaric olan dərəcələr (yəni sətir cəmləri) ilə deyil, yalnız A -nın çəkili daxil olan dərəcələri (yəni sütun cəmləri) ilə həqlə bilər.

cədvəl

Nəzərə alın ki, S simmetrik olmayacaq, çünki A başlanğıcdan simmetrik deyil. Necə ki istiqamətlənmiş qraflar *nüfuz ölçülərini* təpələrin *daxil olan dərəcələri* ilə əlaqələndirir, həmçinin *gregariousness* ölçülərini təpələrin *xaric olan dərəcələri* ilə əlaqələndirmək mümkündür. İntuitiv olaraq, təpənin ünsiyyətçiliyi həmin təpənin istiqamətlənmiş yollar vasitəsilə digər təpələrə asanlıqla çatmaq meyili ilə təyin edilir. Bu, yüksək nüfuzlu təpələrin digər təpələr tərəfindən istiqamətlənmiş yollar vasitəsilə asanlıqla əldə oluna bildiyi nüfuz ölçülərini tamamlayan bir ideyadır. Başqa sözlə, əsas fərq hər iki haldakı tillərin istiqaməti ilə bağlıdır. Biz bu problemin modelləşdirilməsini praktiki tapşırıq olaraq saxlayırıq.

Məsələ 10.6.2 (Gregariousness) *Üç nüfuz ölçüsünün hər birinin (yəni məxsusi vektor, PageRank və dərəcə) uyğun ünsiyyətçilik ölçüsü mövcuddur. Fərq ondadır ki, nüfuz ölçüləri daxil olan tilləri (in-linking), ünsiyyətçilik ölçüləri isə xaric olan tilləri (out-linking) qiymətləndirir. Məsələn, dərəcə ünsiyyətçiliyi təpənin xaric olan dərəcəsidir (outdegree). Uyğun şəkildə seçilmiş matrisin məxsusi vektorları vasitəsilə istiqamətlənmiş qrafın müxtəlif ünsiyyətçilik ölçülərini necə təyin edərdiniz? Bu matris (istiqamətlənmiş) qonşuluq matrisi A , xaric olan dərəcə matrisi Δ_{out} və daxil olan dərəcə matrisi Δ_{in} funksiyası kimi təyin edilməlidir.*

10.6.3 Sol Məxsusi Vektorların Əlaqə Proqnozlaşdırılmasına Tətbiqi

Stoxastik keçid matrisinin sol məxsusi vektorundan əlaqənin proqnozlaşdırılması (link prediction) üçün də istifadə etmək olar. Əlaqənin proqnozlaşdırılmasında biz aralarında əlaqə olmayan, lakin gələcəkdə birləşmə ehtimalı yüksək olan təpə cütlərini tapmağa çalışırıq (bu təpələrin oxşar təpələrlə əlaqəli olması faktına əsaslanaraq). Aşağıda, yanaşma istiqamətlənmiş əlaqənin proqnozlaşdırılması üçün də istifadə oluna bilməsinə baxmayaraq (bax: Məsələ 10.6.3), istiqamətlənməmiş əlaqənin proqnozlaşdırılması halını nəzərdən keçiririk. Verilmiş i təpəsi üçün biz gələcəkdə onunla əlaqə yaratmaq ehtimalı olan bütün təpələri tapmaq istərdik. PageRank-dən əsas fərq yenidənbaşlama ehtimallarının necə təyin edilməsi ilə bağlıdır. İstənilən təpədə yenidən başlamaq əvəzinə, biz yalnız maraq doğuran i təpəsində yenidənbaşlamaya icazə veririk. Buna görə də, əvvəlcə $n \times n$ ölçülü $R = [r_{ij}]$ yenidənbaşlama matrisini hesablayırıq. R matrisi də elə bir stoxastik keçid matrisidir ki, onun i -ci sütunundakı bütün elementlər 1, qalan elementlər isə 0 olaraq təyin edilir. Daha sonra, istiqamətlənməmiş qrafın cari keçid matrisi $\alpha \in (0, 1)$ yenidənbaşlama ehtimalından istifadə etməklə aşağıdakı kimi dəyişdirilir:

$$P \leftarrow (1 - \alpha)P + \alpha R$$

Nəticədə, P -nin sol məxsusi vektorlarının komponentləri i təpəsi üçün *fərdiləşdirilmiş* *PageRank* qiymətlərini təmin edir. α -nın qiyməti fərdiləşdirmə səviyyəsi ilə təpənin əsas sosial populyarlığı arasındakı tarazlığı (trade-off) təmin edir.

Məsələ 10.6.3 (İstiqamətlənmiş Əlaqənin Proqnozlaşdırılması) *Verilmiş təpənin (i) daxil olan tillərini, və (ii) xaric olan tillərini proqnozlaşdırmaq üçün uyğun şəkildə seçilmiş matrislərin sol məxsusi vektorlarından istifadə etmək üçün üsul təklif edin.*

10.7 Reduksiya Olunan Matrislərin Məxsusi Vektorları

Perron-Frobenius teoremi güclü bağlılıq fərziyyəsini ehtiva edir. Bu bölmə həmin fərziyyənin ödənmədiyi halları araşdırır.

10.7.1 İstiqamətlənməmiş Qraflar

$n \times n$ ölçülü qonşuluq matrisi A , dərəcə matrisi Δ və stoxastik keçid matrisi $P = \Delta^{-1}A$ olan istiqamətlənməmiş qrafı nəzərdən keçirək. Əgər istiqamətlənməmiş qraf əlaqəli deyilsə, onun həm qonşuluq matrisi, həm də stoxastik keçid matrisi blok-diaqonal formada təmsil oluna bilər. Xüsusilə, iki əlaqəli komponentdən ibarət qrafın stoxastik keçid matrisi aşağıdakı kimi verilə bilər:

matris elave edəcəksen

Ümumiyyətlə, r əlaqəli komponentə malik qraf diaqonal boyunca r kvadrat bloka sahib olacaqdır. Diaqonal boyunca hər bir P_{ii} bloku həmin təpələr alt çoxluğu daxilində stoxastik keçid matrisidir.

Perron-Frobenius teoremi bildirir ki, əlaqəli qrafın stoxastik keçid matrisinin ən böyük məxsusi vektoru yeganədir və 1 məxsusi qiymətinə malikdir. Qraf əlaqəli olmadıqda, qonşuluq matrisinin ən böyük məxsusi vektorunun yeganəliyi artıq ödənmir. Məsələn, iki komponentli qonşuluq matrisi halında, birinci komponent üçün 1-ləri, ikinci komponent üçün isə 0-ları ehtiva edən məxsusi vektor 1 məxsusi qiymətinə malikdir. Bunun səbəbi odur ki, P_{11} bloku özlüyündə keçid matrisidir və o, P -nin məxsusi vektorunun sıfırdan fərqli hissəsi ilə qarşılıqlı təsirdə olan yeganə hissəsidir. Eynilə, birinci komponent üçün 0-ları, ikinci komponent üçün isə 1-ləri ehtiva edən məxsusi vektor yaratmaq mümkündür. Bu məxsusi vektor da 1 məxsusi qiymətinə malikdir. Başqa sözlə, 1 məxsusi qiymətinə uyğun gələn məxsusi fəzanın ölçülülüyü əlaqəli komponentlərin sayına bərabərdir. Müxtəlif əlaqəli komponentlərə uyğun gələn məxsusi vektorlar bu məxsusi fəzanın bazisini təşkil edir.

Xassə 10.7.1 *İstiqamətlənməmiş qrafın stoxastik keçid matrisinin ən böyük məxsusi vektorlarına (yəni 1 məxsusi qiymətinə malik məxsusi vektorlara) uyğun gələn vektor fəzasının ölçülülüyü həmin qrafdakı əlaqəli komponentlərin sayına bərabərdir.*

Biz həmçinin qeyd edirik ki, xətti alqəbradan istifadə etməklə qrafdakı əlaqəli komponentlərin sayını hesablamaq olar.

Xassə 10.7.2 *Tutaq ki, P istiqamətlənməmiş qrafın stoxastik keçid matrisidir. Onda $P - I$ matrisinin sıfır fəzasının (null space) ölçülülüyü qrafdakı əlaqəli komponentlərin sayını verir.*

Xassə 10.7.1-dən açıq şəkildə görünür ki, P matrisinin məxsusi fəzası (1 məxsusi qiyməti üçün) $P - I$ -nin sıfır fəzasıdır. Matrisin sıfır fəzasını Təkrar Vektor Analizi (SVD) vasitəsilə asanlıqla hesablamaq olar.

10.7.2 İstiqamətlənmiş Qraflar

İstiqamətlənmiş qraflarda əlaqəlilik anlayışı daha mürəkkəbdir, çünki güclü bağlılıq kimi anlayışların tərifində tilin istiqaməti əhəmiyyət daşıyır. İstiqamətlənməmiş qraflarda olduğu kimi, biz stoxastik keçid matrisi ilə işlədiyimizi fərz edəcəyik.

Birincisi, istiqamətlənmiş qonşuluq matrisindən stoxastik keçid matrisinin yaradılması həmişə mümkün deyil, çünki bəzi təpələrin heç bir xaric olan tili olmaya bilər. Başqa sözlə, qonşuluq matrisindəki müvafiq sətir 0-lardan ibarət olur, baxmayaraq ki, onun sütununda sıfırdan fərqli elementlər mövcuddur. Belə sətirləri cəmi 1 olacaq şəkildə normallaşdırmaq qeyri-mümkündür. Buna görə də, aşağıdakı təhlil belə çıxmaz nöqtələrin mövcud olmadığını fərz edəcəkdir. Belə çıxmaz nöqtələr mövcud olduqda, növbəti təhlili asanlaşdırmaq üçün ehtimalı 1 olan öz-özünə dövrə əlavə etmək olar. Öz-özünə dövrlərin əlavə edilməsinin bu növü tez-tez *PageRank* və kollektiv təsnifat kimi bir çox maşın öyrənməsi alqoritmlərində (çıxmaz nöqtələr mövcud olduqda) həyata keçirilir. Təhlili asanlaşdırmaq üçün etdiyimiz digər bir fərziyyə odur ki, tillərin istiqamətləri nəzərə alınmadıqda qraf tam əlaqəlidir.

Qraf güclü bağlı olmadıqda, matris blok yuxarı üçbucaqlı (block upper-triangular) olacaqdır; bu zaman diaqonal həmin diaqonal blokların üzərində yerləşən bəzi əlavə sıfırdan fərqli elementlərlə birlikdə güclü bağlı komponentlərin kvadrat bloklarını ehtiva edir. Bu əlavə elementlər yalnız təpə blokları arasında biristiqamətli gəzintilərə imkan verir. Blok strukturunun bu növünü təsadüfi addımlar baxımından başa düşmək ən asanıdır. Güclü bağlı qraflar elə *erqodik Markov zəncirləri* ilə nəticələnir ki, burada dayanıqlı hal ehtimalları təsadüfi gəzintinin haradan başlanmasından asılı deyil. Bundan əlavə, dayanıqlı halda bütün təpələrin əldə olunma ehtimalı sıfırdan fərqlidir.

Güclü bağlı olmayan qraflar bu xassələri ödəmir. Belə qraflar iki növ təpəni ehtiva edir:

1. Birinci növ qrafdakı *ötürücü təpələr çoxluğu*dur. Ötürücü təpələr çoxluğu elə maksimum təpələr çoxluğu ki, bu çoxluğa aid təpələr ilə digər bütün təpələr arasındakı tillərin istiqaməti həmişə ötürücü çoxluğa aid təpələrdən xaricə doğru olur. Nəzərə alın ki, ötürücü çoxluqdakı təpələr bir-biri ilə əlaqəli/güclü bağlı ola bilər, olmaya da bilər, buna görə də ötürücü təpələrin altqrafı üzərindəki til strukturu ixtiyari ola bilər. Bu təpələr ötürücü (transient) adlanır, çünki təsadüfi gəzinti dayanıqlı halda

heç vaxt bu təpələrə baş çəkməyəcək. Gəzinti bu komponentdən çıxdıqdan sonra, dayanıqlı halda həmin komponentə qayıtmaq artıq mümkün deyil. Məsələn, Şəkil 10.5(a)-nın halında 9-cu təpə yeganə ötürücü təpədir. Digər tərəfdən, Şəkil 10.5(b)-də 1, 4, 5, 6 və 7 təpələri ötürücü təpələrdir. Ötürücü təpələr bu şəkillərdə 'T' hərfi ilə işarələnmişdir. Oxucu təsadüfi gəzintinin bu təpələrin hər hansı birindən başlayaraq sonda bu çoxluqdan kənarda yerləşən bir təpəyə çatacağını və nəticədə bu təpələrin heç birinə yenidən baş çəkməyin heç vaxt mümkün olmayacağını yoxlamaq üçün bir anlıq vaxt ayıra bilər. Ötürücü komponent reduksiya olunan qrafların vacib xassəsidir. Əgər əlaqəli qrafın ötürücü komponenti yoxdursa, deməli, o, həm də güclü bağlıdır.

şəkil yerləşdir 2 eded

Şəkil 10.5: Güclü bağlı olmayan istiqamətlənmiş qraf nümunələri. Ötürücü təpələr 'T' ilə, uducu komponentlərə aid təpələr isə 'A1' və 'A2' ilə işarələnmişdir.

- Ötürücü təpələr çoxluğundan əlavə, qraf *uducu komponentlər* adlandırılan və təpələrə görə kəsişməyən (vertex-disjoint) l ədəd komponent ehtiva edir. Hər bir uducu komponent öz təpələr çoxluğu tərəfindən induksiya olunmuş altqraf baxımından güclü bağlıdır. Bundan əlavə, uducu komponentin yalnız ötürücü təpələrdən gələn daxil olan tilləri var, digər uducu komponentlərlə əlaqəsi yoxdur və xaric olan tilləri mövcud deyil. Şəbəkədəki təsadüfi təpədən başlayan təsadüfi gəzintidən dayanıqlı halda (steady-state) hər bir uducu komponentə baş çəkmə ehtimalı sıfırdan fərqlidir. Bununla belə, dayanıqlı hal ehtimalı təsadüfi gəzintinin başladığı təpədən asılıdır. Şəkil 10.5(a)-da 9-cu təpə istisna olmaqla bütün təpələri ehtiva edən tək bir uducu komponent mövcuddur. Digər tərəfdən, Şəkil 10.5(b) 'A1' və 'A2' ilə işarələnmiş iki uducu komponent ehtiva edir. Nəzərə alın ki, təsadüfi gəzintinin 1-ci təpədən başlanması həmişə A1 uducu komponentinə çatacaq, lakin heç vaxt A2 uducu komponentinə çatmayacaq. Gəzintiyə 4-cü təpədən başlamaq həm A1, həm də A2-yə çatmağa imkan verəcək.

Ümumiliyi pozmadan fərz edirik ki, belə bir qrafın təpələri aşağıdakı kimi ardıcılıqla düzülmüşdür. Bu qrafın birinci bloku bütün ötürücü təpələri ehtiva edir. Bu çoxluq üçün a_{ij} hər bir ötürücü i təpəsi üçün sıfırdan fərqli ola bilər və j 1-dən n -ə qədər istənilən qiymət ala bilər. Qalan bütün digər l uducu komponent istiqamətlənməmiş matrislərdə olduğu kimi blok-diaqonal formada düzülmüşdür. Məsələn, bir ötürücü çoxluğa və üç uducu komponentə malik qraf, təpə indeksləri uyğun şəkildə yenidən sıralandıqda (ötürücü təpələri birinci, uducu komponentlərin təpələrini isə bir-prinin ardınca ardıcıl olaraq yerləşdirmək üçün) stoxastik keçid matrisinin aşağıdakı blok strukturuna malik olacaqdır:

matrix elave edeceksen

Qeyd etmək vacibdir ki, P_{22} , P_{33} və P_{44} kvadrat blokları uducu komponentlər daxilindəki tillərə uyğundur və tam stoxastik keçid matrisləridir. Bu matris 1 məxsusi qiymətinə aid olan məxsusi fəzada üç məxsusi vektora malikdir. Bu məxsusi vektorların hər biri bir uducu komponent vasitəsilə təyin oluna bilər. Sol məxsusi vektorları müzakirə etmək daha asandır. Əvvəlcə (uducu komponentlərə uyğun gələn) P_{22} , P_{33} və P_{44} bloklarının hər birinin əsas sol

məxsusi vektorlarını ayrıca hesablamaq olar. Uducu altmatrisin hər belə məxsusi vektorundan, daha böyük məxsusi vektorun qalan komponentlərini sıfıra təyin etməklə P -nin sol məxsusi vektorunu təyin etmək üçün istifadə oluna bilər. Buna görə də, belə reduksiya olunan qraflarla təyin olunan Markov zəncirləri $\pi^T P = \pi^T$ dayanıqlı hal tənliyi üçün birdən çox həllə malikdir.

İstiqamətlənmiş qrafların tamamilə əlaqəsiz olması (yəni tillərin istiqamətindən asılı olmayaraq əlaqəsiz olması) mümkün olsa da, bu vəziyyət maşın öyrənməsi tətbiqlərində nadir hallarda baş verir. Bu fəsilə biz bu halı nəzərə almırıq, çünki o, tətbiqyönümlü nöqtəyi-nəzərdən o qədər də maraqlı deyil. Reduksiya olunmayan bütün əlaqəli qraflar güclü bağlı komponentlərə birtərəfli əlaqəsi olan ən azı bəzi ötürücü (transient) təpələrə malik olacaqlar. Qrafın tamamilə əlaqəsiz olmadığını fərz etsək, reduksiya olunan qrafın əsas strukturu həmişə Şəkil 10.6 şəklində özünü göstərir. Nəzərə alın ki, ötürücü təpələr altqraf kimi nəzərdən keçirildikdə güclü bağlı (və ya hətta əlaqəli) olmaq məcburiyyətində deyil. Məsələn, Şəkil 10.5(b)-dəki ötürücü təpələr ('T' ilə işarələnmişdir) altqraf kimi nəzərdən keçirildikdə bir-biri ilə əlaqəli deyil. Şəkil 10.6-dakı peyk komponentlərinin (satellite components) hər biri uducu komponentdir. Əgər tam qraf üzərində təsadüfi gəzinti yerinə yetirilərsə və təsadüfi gəzinti təsadüfən uducu komponentə daxil olarsa, gəzinti heç vaxt həmin komponentdən çıxmayacaq. Təpələrin bəziləri ötürücü olduğu müddətcə, reduksiya olunan şəbəkənin yalnız bir uducu komponent ehtiva etməsi mümkündür. Əslində, istiqamətlənmiş, əlaqəli qrafın qonşuluq matrisi yalnız və yalnız qrafda ötürücü təpələr mövcud olduqda reduksiya olunandır.

şəkil əlavə edəcəksən

Biz bu növ reduksiya olunan matrislərin bir sıra genişləndirilmiş xassələrini təqdim edirik. Tutaq ki, P ən azı bir ötürücü təpəyə və l uducu komponentə malik olan əlaqəli (lakin güclü bağlı olmayan) istiqamətlənmiş qrafın $n \times n$ ölçülü stoxastik keçid matrisidir. Biz P -də əsas məxsusi fəzanın intuitiv izahını təqdim edirik:

1. 1 əsas məxsusi qiymətinə uyğun gələn məxsusi fəzanın ümumi rəngi həmişə l -ə bərabərdir, burada l uducu komponentlərin sayıdır.
2. Əsas sol məxsusi vektorların məxsusi fəza bazisini ələ qurmaq mümkündür ki, hər bir məxsusi vektor hansısa uducu komponentə "məxsus olsun". j -ci uducu komponentdən başlayan təsadüfi gəzintidə i təpəsinin dayanıqlı hal ehtimalı j -ci uducu komponentə aid olan sol məxsusi vektorun i -ci komponentində yerləşir.
3. Əsas sağ məxsusi vektorların məxsusi fəza bazisini ələ qurmaq mümkündür ki, hər bir məxsusi vektor hansısa uducu komponentə "məxsus olsun". j -ci uducu komponentə aid olan sağ məxsusi vektorun i -ci komponenti π_i^j təpəsindən başlayan gəzintinin j -ci uducu komponentdə başa çatması ehtimalını ehtiva edir. Bu ehtimal ötürücü düyünlər üçün kəsr ola bilər və j komponentinə aid düyünlər üçün 1-ə bərabərdir. Nəzərə alın ki, bu π_i^j məxsusi vektorun cəmi özlüyündə 1-lərdən ibarət məxsusi vektordur (reduksiya olunmayan halda əldə etdiyimiz də məhz budur). l məxsusi vektordan ibarət bu baza kollektiv təsnifat kimi tətbiqlərdə çox faydalıdır (növbəti bölməyə və Məsələ 10.8.1-ə baxın).

10.8 Maşın Öyrənməsi Tətbiqləri

Bu bölmədə biz qrafların bir sıra maşın öyrənməsi tətbiqlərini müzakirə edəcəyik.

10.8.1 Təpə təsnifatına tətbiq

Reduksiya olunan matrislərdən qraflarda təpələrin təsnifatı tətbiqləri üçün istifadə etmək olar. Təpələrin təsnifatı problemi həm də *kollektiv təsnifat* adlanır. Kollektiv təsnifat problemi simmetrik A qonşuluq matrisinə malik istiqamətlənməmiş qraflara uyğundur. Kollektiv təsnifatda təpələrin bir alt çoxluğu $\{1, \dots, k\}$ ilə işarələnən k etikətdən biri ilə etikətlənir. Təpələrin bəziləri etikətlənməmiş ola bilər. Məqsəd qrafın strukturuna və məlum etikətlərə əsasən etikətlənməmiş təpələri təsnif etməkdir. Bu problem çox vaxt sosial şəbəkələrdə yaranır; burada həmin xüsusiyyətlərə malik digər (məlum) aktyorlara əsasən müəyyən xüsusiyyətlərə malik aktyorları (məsələn, müəyyən məhsula olan maraq) tapmağa çalışırlar. Buna görə də, məlum aktyorlar öz xüsusiyyətləri ilə etikətlənə bilər. 'A' və ya 'B' ilə etikətlənmiş təpələr alt çoxluğuna malik istiqamətlənməmiş qrafın nümunəsi Şəkil 10.7(a)-da göstərilmişdir. Buna görə də, bu xüsusi nümunə $k = 2$ olan ikili (binar) etiket tənzimləməsinə uyğundur. Müzakirəni asanlaşdırmaq üçün fərz edək ki, A qonşuluq matrisinin til çəkilişi binar qiymətlərdir. Şəkil 10.7(a)-da bir çox təpələr etikətlənməmişdir və məqsəd məhz bu təpələri təsnif etməkdir.

Bu problemin həlli üçün əsas prinsip sosial şəbəkələrdə *homofiliya* prinsipindən istifadə etməkdir. İdeya ondan ibarətdir ki, təpələr oxşar xüsusiyyətlərə malik təpələrlə əlaqəli olmağa meyllidir. Buna görə də, etikətlənməmiş təpədən başlayan təsadüfi gəzintinin öz etiket qiymətinə uyğun gələn etikətlənmiş təpəyə daha əvvəl çatmaq ehtimalı daha yüksəkdir. Buna əsasən, bu problemin həlli üçün ehtimalı yanaşma aşağıdakı kimidir:

Etikətlənməmiş təpə verildikdə, etikətlənmiş təpəyə çatana qədər qonşuluq matrisinin stoxastik keçid matrisindən istifadə edərək təsadüfi gəzinti həyata keçirin. Təsadüfi gəzintinin başladığı mənbə (etikətlənməmiş) təpənin proqnozlaşdırılan sinif etiketi kimi təyinat (etikətlənmiş) təpənin müşahidə olunan etiketini çıxışa verin.

Daha yüksək dayanıqlılıq üçün hər bir sinfə aid təpəyə çatmaq *ehtimalını* hesablamaq olar. Bu yanaşmanın arxasındakı intuitsiya ondan ibarətdir ki, gəzintinin başlanğıc i təpəsinin yaxınlığındakı etikətlənmiş təpələrdə başa çatma ehtimalı daha yüksəkdir. Buna görə də, müəyyən bir sinfə aid bir çox təpə onun yaxınlığında yerləşdikdə, i təpəsinin həmin siniflə etikətlənmə ehtimalı daha yüksək olur. Şəkil 10.7(a)-nın xüsusi halında, qrafın topologiyasına görə, X test təpəsindən başlayan istənilən təsadüfi gəzinti 'B' etiketindən əvvəl həmişə 'A' etikətinə çatacaqdır. Bununla belə, elə test təpələri də seçmək mümkündür ki, orada həm 'A', həm də 'B' etikətlərinə çatmağın sıfırdan fərqli ehtimalı mövcuddur. Məsələn, əgər təsadüfi gəzintiyə Y test təpəsindən başlanarsa, o zaman ya 'A', ya da 'B' etikətinə uyğun gələn təpəyə daha əvvəl çatmaq olar.

Vacib fərziyyələrdən biri odur ki, qraf *etiketə görə əlaqəli* olmalıdır. Başqa sözlə, təsadüfi gəzintidə hər bir etikətlənməmiş təpə hər hansı etikətlənmiş təpəyə çata bilməlidir. İstiqamətlənməmiş qraflar üçün bu o deməkdir ki, qrafın hər bir əlaqəli komponenti ən azı bir etikətlənmiş təpəni ehtiva etməlidir. Aşağıdakı müzakirədə bütün istiqamətlənməmiş qrafın

əlaqəli olduğu fərz ediləcək; yalnız bir əlaqəli komponentə malik istənilən istiqamətlənməmiş qraf həmişə etiketə görə əlaqəli olan modifikasiya edilmiş keçid matrisinə gətirib çıxaracaq.

Yanaşma təsadüfi gəzintilərə əsaslandığı üçün ilk addım istiqamətlənməmiş $n \times n$ ölçülü A qonşuluq matrisindən (istiqamətlənmiş) stoxastik P keçid matrisini yaratmaqdır. Tutaq ki, Δ

əsas diaqonalının i -ci elementində çəkili dərəcəni $\delta_i = \sum_j a_{ij} = \sum_j a_{ji}$ ehtiva edən (diaqonal)

dərəcə matrisidir. Bu fəslin bütün digər tətbiqlərində olduğu kimi, qonşuluq matrisi sol-normallaşdırmadan (left-normalization) istifadə etməklə stoxastik keçid matrisinə çevrilir:

$$P = \Delta^{-1}A$$

-----şəkil əlavə edəcəksən-----

Çünki bu keçid matrisi istiqamətlənməmiş qraftan əldə edilmişdir, o, həmişə reduksiya olunmayan matris olacaqdır. Uyğun güclü bağlı qraf Şəkil 10.7(b)-də təsvir edilmişdir və müxtəlif tillər üzərindəki ehtimallar açıq şəkildə göstərilmişdir. Eyni illüstrasiya Şəkil 10.7(c)-də göstərilmişdir, lakin (qarışıqlığın qarşısını almaq üçün) tillər üzərindəki ehtimallar verilməmişdir.

Baxmayaraq ki, qrafda təsadüfi gəzintiləri modeləşdirmək üçün bu keçid matrisindən istifadə edə bilərik, belə bir yanaşma gəzintinin *ilk dayandığı nöqtəni* təmin etməyəcək. Başqa sözlə, biz təsadüfi gəzintiləri elə modeləşdirməliyik ki, onlar həmişə etikətlənmiş təpələrə ilk çatdıqları zaman başa çatsınlar. Buna etikətlənmiş təpələrdən xaric olan tilləri silmək və onları öz-özünə döngələrlə əvəz etməklə nail olmaq olar. Bu, yalnız bir təpədən ibarət təkli uducu komponentlə nəticələnir ki, biz bunu *uducu təpə* adlandırırıq. Belə təpələr uducu təpələr adlanır, çünki onlar daxil olan keçiddən sonra təsadüfi gəzintini tələyə salırlar. Belə uducu təpələr yaratmaqda məqsəd təsadüfi gəzintinin çatdığı ilk etikətlənmiş düyün tərəfindən tutulmasını (udulmasını) təmin etməkdir.

Uducu təpələrin təsirini nəzərə almaq üçün stoxastik keçid matrisi P -ni modifikasiya etmək lazımdır. Hər bir uducu i təpəsi üçün P -nin i -ci sətri eynilik matrisinin i -ci sətri ilə əvəz edilir. Bundan sonra biz fərz edəcəyik ki, P işarəsi ilə göstərilən matris bu modifikasiyanı özündə ehtiva edir (və buna görə də 10.7 tənliyinə əsasən dəqiq olaraq $\Delta^{-1}A$ -ya bərabər deyil). Yekun keçid qrafının nümunəsi Şəkil 10.7(d)-də təsvir edilmişdir. Alınan matris artıq reduksiya olunmayan deyil, çünki alınan qraf artıq güclü bağlı deyil; uducu təpədən başqa heç bir təpəyə çatmaq mümkün deyil. Nəzərə alın ki, bu qraf tam olaraq Şəkil 10.6-nın strukturuna malikdir, çünki uducu komponentlərin hər biri təkli (etikətlənmiş) təpədir və bütün etikətlənməmiş təpələr ötürücüdür (transient). Keçid matrisi P reduksiya olunan olduğundan, onun 1 məxsusi qiymətinə malik yeganə məxsusi vektoru yoxdur. Əksinə, onun uducu təpələrin sayı qədər 1 məxsusi qiymətinə malik əsas məxsusi vektorları mövcuddur.

İstənilən verilmiş başlanğıc i təpəsi üçün dayanıqlı hal ehtimalı paylanması yalnız etikətlənmiş təpələrdə müsbət qiymətlərə malikdir. Bunun səbəbi odur ki, etiketə görə əlaqəli qrafda təsadüfi gəzinti gec-tez uducu təpəyə çatacaq və həmin təpədən bir daha çıxmayacaq. Buna görə də, əgər başlanğıcda etikətlənməmiş i təpəsi üçün etikətlənmiş düyünlərin dayanıqlı hal ehtimalı paylanmasını qiymətləndirmək mümkündürsə, onda hər bir sinifdəki etikətlənmiş təpələrin ehtimal qiymətləri aqreqatlaşdırıla bilər. Ən yüksək ehtimala malik sinif etikətlənməmiş i təpəsinin uyğun etiketi kimi qeyd olunur.

Nəzərə alın ki, P^r -in (i, j) -ci elementi istənilən i təpəsindən başlayan r uzunluqlu təsadüfi gəzintinin istənilən j təpəsində başa çatma ehtimalını verir. Uducu təpələrdəki öz-özünə

döngələrə görə, r -dən qısa bütün gəzintilər ehtimala avtomatik olaraq daxil edilir (çünki qalan addımlar öz-özünə döngənin daxilində tamamlana bilər). Buna görə də, P^∞ ehtimalların dayanıqlı hal matrisidir ki, burada P^∞ -in (i, j) -ci elementi i təpəsindən başlayan gəzintinin j təpəsində başa çatma ehtimalını təmin edir. Hər bir sətir üçün müxtəlif etikətlərə aid siniflərin ehtimallarını aqreqatlaşdırmaq istəyirik. Aşağıda görəcəyimiz kimi, buna sadə matris vurması vasitəsilə nail olmaq olar.

Tutaq ki, Y $n \times k$ ölçülü matrisdir ki, burada (i, c) -ci element, əgər i -ci təpə etikətlənmişdirsə və $c \in \{1, \dots, k\}$ sinfinə məxsusdursa, 1-ə bərabərdir. Onda P^∞ -in hər bir sətirindəki etikətlənmiş təpələrin ehtimallarının aqreqatlaşdırılması matrisi ilə verilir. Başqa sözlə, müxtəlif təpələr üçün siniflərin ehtimallarının $n \times k$ ölçülü Z matrisini aşağıdakı kimi əldə edə bilərik:

$$Z = P^\infty Y$$

Etiketlənməmiş i təpəsi (sətiri) üçün Z matrisində maksimum ehtimala malik sinif onun sinif etiketi kimi qeyd oluna bilər. Bu yanaşma həm də etikətlərin yayılması üçün *görüşmə yanaşması* [9] adlandırılır. P^∞ necə hesablanır?

Ehtimallardan biri P^∞ -i hesablamaq üçün P -ni öz-özünə vurmağa davam etməkdir. Prosesi sürətləndirmək üçün məxsusi qiymətlərə görə ayırma (eigendecomposition) üsullarından istifadə etmək olar. Lakin biz $n \times n$ ölçülü böyük matrislərlə (P^∞ kimi) işləmək istəmirik. Buna görə də, daha səmərəli (lakin ekvivalent) yanaşma *iterativ etiket yayılmasıdır* [143].

İterativ etiket yayılmasında biz başlanğıcda $Z^{(0)} = Y$ qəbul edirik və sonra iterasiya indeksinin t artan qiymətləri üçün aşağıdakı yeniləmədən təkrar-təkrar istifadə edirik:

$$Z^{(t+1)} = PZ^{(t)}$$

Asanlıqla görmək olar ki, $Z^{(\infty)}$ 10.8 Tənliyindəki Z -nin qiyməti ilə eynidir. Üstəlik, konvergensiyada Z -nin hər bir sütunu P -nin əsas sağ məxsusi vektorudur. Hər bir əsas məxsusi vektor tək uducu komponentdən deyil, çoxlu uducu komponentlərə malik etikete uyğun gəlir. Bundan əlavə, bu halda uducu komponentlər təkli (singleton) təpələrdir. Aşağıdakı tapşırıq bu ideyanı heç bir xüsusi struktura malik olmayan uducu komponentlərin əsas məxsusi vektorlarının tapılmasına ümumiləşdirir.

Məsələ 10.8.1 (Sağ Əsas Məxsusi Vektorlar)

Əvvəlcədən sərhədləri müəyyən edilmiş l uducu komponentə malik istiqamətlənmiş qrafı nəzərdən keçirin. Aşağıdakı xassəni ödəyən l əsas sağ məxsusi vektordan ibarət baza yaratmaq üçün iterativ etiket yayılmasındakı ideyalardan necə istifadə edə biləcəyinizi müzakirə edin: j -ci əsas məxsusi vektorun i -ci komponenti i təpəsindən başlayan gəzintinin j -ci uducu komponentdə başa çatması ehtimalına bərabər olmalıdır.

10.8.2 Çoxölçülü Məlumatlara Tətbiqlər

Qraflar həmçinin çoxölçülü məlumatlar üzərindəki müxtəlif maşın öyrənməsi tətbiqlərinə də tətbiq oluna bilər. Bunun səbəbi odur ki, istənilən növ çoxölçülü məlumat dəsti *oxşarlıq qrafı*

kimi modeləşdirilə bilər. $\bar{X}_1, \dots, \bar{X}_n$ ilə işarələnmiş n məlumat nümunəsinə malik çoxölçülü məlumat dəstini nəzərdən keçirin. İlk addım hər bir məlumat nöqtəsinin k -ən yaxın qonşularını hesablamaqdır. $\bar{X}_i$ və $\bar{X}_j$ nöqtələrinin hər hansı cütü arasındakı oxşarlıq Gaussian kernel-i istifadə etməklə hesablanı bilər:

$$K(\bar{X}_i, \bar{X}_j) = e^{-\|\bar{X}_i - \bar{X}_j\|^2 / (2 \cdot \sigma^2)}$$

Burada σ Gaussian kernel-nin zolaq genişliyidir (bax: Fəsil 9, Cədvəl 9.1). Nəzarət olunan tətbiqlər üçün σ -nın qiyməti çox vaxt nümunədənəknar məlumatlardan istifadə etməklə tənzimlənir. Nəzarətsiz tətbiqlər üçün σ -nın qiyməti nöqtələr arasındakı bütün cütlüklü Evklid məsafələrinin medianı tərtibində seçilir.

i -ci təpənin $\bar{X}_i$ məlumat nöqtəsinə uyğun gəlidiyi qraf qurulur. Oxşarlıq qiymətindən 10.5-ci bölmədə müzakirə olunduğu kimi, qarşılıqlı k -ən yaxın qonşu qrafını hesablamaq üçün istifadə etmək olar. Tilin çəkisi 10.10 Tənliyində təqdim olunan nüvə oxşarlığı qiymətinə təyin edilir. Nəticə etibarilə, bu qraf üzərində klasterləşmə və ya təsnifat kimi bu fəsilə müzakirə olunan istənilən tətbiqlərdən istifadə oluna bilər. Təsnifat halında qraf həm etiketlenmiş, həm də etiketlenməmiş təpələr üzərində qurulur. Buna görə də, ənənəvi təsnifatdan fərqli olaraq, təsnifat məlumatlardakı etiketlenməmiş nümunələrdən faydalanır. Bu cür yanaşma etiketlenmiş nümunələrin sayı az olduqda faydalı ola bilər. Daha yaxşı təsnifat üçün etiketlenməmiş nümunələrdən istifadə *yarım-nəzarətli təsnifat* adlanır. Bundan əlavə, bu yanaşmadan yalnız çoxölçülü məlumatlar üçün deyil, həm də obyektlər arasında oxşarlıq funksiyasının hesablanı biləcəyi istənilən növ məlumat üçün istifadə etmək olar. Ümumiyyətlə, qraf yerləşdirmələrinin müxtəlif formaları (məsələn, spektral yerləşdirmələr) nüvə üsullarının xüsusi halları kimi nəzərdən keçirilə bilər. İstənilən nüvə üsulu kimi, oxşarlıq qrafı və onun yerləşdirmələri istənilən məlumat növü üçün istifadə oluna bilər.

10.9 Xülasə

Bu fəsil qrafların xətti alqəbrasını müzakirə edir. Qrafların təpələr arasındakı gəzintilər və əlaqəlilik kimi bir çox vacib struktur xassələri qonşuluq matrisinin xətti alqəbrasından çıxarıla bilər. Qrafların spektral təhlili üzrə əsas nəticələrin təməlinə duran fundamental nəticə Perron-Frobenius teoremidir. Qraflarla əlaqəli xüsusi matris növü əsas məxsusi vektoru 1 məxsusi qiymətinə malik olan stoxastik keçid matrisidir. Stoxastik keçid matrisinin dominant sol məxsusi vektoru və dominant sağ məxsusi vektor(lar)ı müxtəlif növ tətbiqlərə malikdir. Dominant sol məxsusi vektor reyting tərtibi, sağ məxsusi vektorlar isə klasterləşdirmə üçün istifadə olunur. Klasterləşdirmə üçün nüvə (kernel) üsullarının istifadəsinə təxminən ekvivalent olan simmetrik normallaşdırılmış qonşuluq matrisindən də istifadə etmək olar. Qonşuluq matrisinin müxtəlif normallaşdırma formaları müxtəlif mərkəzlilik və nüfuz ölçülərinin əldə edilməsinə kömək edir. Qrafların kollektiv təsnifatını yerinə yetirmək məqsədilə stoxastik keçid matrislərinin dəyişdirilmiş versiyalarının məxsusi vektorlarını da hesablamaq olar. Bütün qraf əsaslı maşın öyrənməsi tətbiqləri əsas obyektlər üzərində uyğun oxşarlıq qraflarının qurulması ilə istənilən verilənlər tiplərinə ümumiləşdirilə bilər.

10.10 Əlavə Ədəbiyyat

Spektral qraf nəzəriyyəsinin əsasları [25, 29] mənbələrində mövcuddur. Daha çox tətbiqyönümlü yanaşmanı [40] mənbəsində tapmaq olar. Qraf Laplasianlarının və spektral klasterləşdirmənin əsaslarını Luxburg-un [84] tanınmış icmalında tapmaq olar. Spektral klasterləşdirmənin simmetrik və asimmetrik variantları [98, 115] mənbələrində təklif edilmişdir. Simmetrik variantı nüvə (kernel) üsulu ilə əlaqələndirmək daha asan olsa da, hər iki variant təxminən ekvivalentdir. Orijinal *PageRank* alqoritm [24] mənbəsində təklif edilmişdir. Müxtəlif növ mərkəzilik ölçülərinin müzakirəsini [138] mənbəsində tapmaq olar. Etiket yayılması alqoritminin müxtəlif təqdimatları [9, 143] mənbələrində verilir. Qraflarda təpələrin təsnifatı üzrə icmalları [17, 82] mənbələrində tapmaq olar.

10.11 Tapşırıqlar

1. İki qrafın $n \times n$ ölçülü A_1 və A_2 qonşuluq matrislərini nəzərdən keçirin. Tutaq ki, qrafların *izomorf* olduğu məlumdur. İki qraf o zaman izomorf hesab olunur ki, onlardan biri digərinin təpələrinin yerini dəyişməklə (yenidən nömrələməklə) əldə edilsin. Göstərin ki, izomorf qrafların eyni məxsusi qiymətləri vardır. (*İpucu: Onların qonşuluq matrisləri arasındakı cəbri əlaqənin xarakteri necədir? Ehtiyac olduğu təqdirdə istənilən yeni matris daxil edə bilərsiniz.*)
2. Tutaq ki, sizə istiqamətlənməmiş qrafın P stoxastik keçid matrisinin məxsusi vektorları və məxsusi qiymətləri verilmişdir. Bu məxsusi vektorlar və məxsusi qiymətlərdən istifadə edərək P^∞ -i necə sürətlə hesablaya biləcəyinizi müzakirə edin.
3. Tutaq ki, Δ $n \times n$ ölçülü (istiqamətlənməmiş) A qonşuluq matrisinin çəkili dərəcə matrisidir və $\bar{e}_1, \dots, \bar{e}_n$ stoxastik keçid matrisinin $P = \Delta^{-1}A$ n məxsusi vektorudur. Göstərin ki, $\bar{e}_i$ və $\bar{e}_j$ məxsusi vektorlarının istənilən cütü Δ -ortogonaldır. Başqa sözlə, $\bar{e}_i$ və $\bar{e}_j$ məxsusi vektorlarının istənilən cütü aşağıdakı şərti ödəməlidir:

$$\bar{e}_i^T \Delta \bar{e}_j = 0$$

4. Göstərin ki, əlaqəli, istiqamətlənməmiş qrafın stoxastik keçid matrisinin bütün məxsusi vektorları (birinci məxsusi vektordan başqa) həm müsbət, həm də mənfi komponentlərə malik olacaqdır.
5. Həm də ikitərəfli olan $n \times n$ ölçülü istiqamətlənməmiş qrafın A qonşuluq matrisini nəzərdən keçirin. İkitərəfli qrafda n təpə müvafiq olaraq n_1 və n_2 təpədən ibarət iki V_1 və V_2 təpə çoxluğuna bölünə bilər ki, bütün tillər V_1 -in təpələri ilə V_2 -nin təpələri arasında baş versin. Belə bir qrafın qonşuluq matrisi $n_1 \times n_2$ ölçülü B matrisi üçün həmişə aşağıdakı formaya malikdir:

-----matris-----

Baxmayaraq ki, A simmetrikdir, B simmetrik olmaya bilər. A -nın məxsusi vektorları və məxsusi qiymətləri verildikdə, B -nin SVD-ni necə tez yerinə yetirə biləcəyinizi göstərin (və əksinə).

6. n təpə üzərində tam istiqamətlənmiş qraf təyin edilmişdir və o, hər bir təpə cütü arasında hər iki istiqamətdə (öz-özünə döngələr istisna olmaqla) bütün mümkün $n(n - 1)$ tilini ehtiva edir. Hər bir tilin çəkisi 1-dir.

(a) Bütün məxsusi qiymətlərin niyə həqiqi olmasının qısa səbəbini verin.

(b) Məxsusi qiymətlərin cəminin niyə 0 olmasının qısa səbəbini verin.

(c) Göstərin ki, bu qrafın $(n - 1)$ -ə bərabər bir məxsusi qiyməti və -1 -ə bərabər $n - 1$ məxsusi qiyməti var. [Qonşuluq matrisini $\overline{11}^T - I$ kimi ifadə edin.]

7. Tam ikitərəfli qraf (bax: 5-ci Tapşırıq) 4 təpə üzərində təyin edilmişdir ki, hər bir bölmədə 2 təpə yerləşir. İki bölmədən götürülmüş hər bir təpə cütü arasında hər iki istiqamətdə 1 çəkili til mövcuddur. Bu qrafın məxsusi qiymətlərini tapın. Bu nəticəni hər bir bölmədə n təpənin yerləşdiyi və $2n$ təpədən ibarət olan tam ikitərəfli qraf halına ümumiləşdirə bilərsinizmi?

8. İstiqamətlənməmiş A qonşuluq matrisi üçün simmetrik normallaşdırılmış qonşuluq matrisini yaratdığınızı fərz edək. Siz qərara gəldirsiniz ki, bəzi təpələr “vacibdir” və onlar spektral klasterləşmədəkiyə oxşar yerləşdirmədə $\gamma > 1$ nisbi çəkisinə malik olmalıdırlar, digər təpələr isə yalnız 1 çəkisi almalıdır.

(a) Məqsəd funksiyasında “vacib” təpələrin γ nisbi çəkisinə malik olduğu yerləşdirmə yaradan çəkili matris faktorizasiyası modelini təklif edin. Matris faktorizasiyası modeli $\gamma = 1$ olduqda simmetrik spektral klasterləşmə ilə eyni yerləşdirməni təmin etməlidir.

(b) Əgər qrafdakı bəzi təpələr etiketlenmişdirsə, bu yanaşma ilə sinfə həssas yerləşdirməni necə yarada biləcəyinizi göstərin.

(c) Sizə çoxölçülü məlumatlarla işləyən qara qutu təsnifçisi verilib. γ -nı uyğun şəkildə necə seçə biləcəyinizi və onu qismən etiketlenmiş qrafın etiketlenməmiş təpələrinin kollektiv təsnifatı üçün necə istifadə edə biləcəyinizi göstərin.

9. 10.8.2 Bölməsində təklif olunan oxşarlıq qrafı anlayışından istifadə edən, çoxölçülü məlumatlarda kənar elementlərin aşkar edilməsi üçün yerləşdirmə əsaslı alqoritm təklif edin. Yerləşdirmənin uyğun ölçülülüyünün seçilməsini və bu seçimin klasterləşmə problemi halından nədən fərqləndiyini müzakirə edin.

10. Tutaq ki, sizə elə çox böyük qraf verilib ki, spektral klasterləşmə üçün simmetrik S oxşarlıq matrisi sərəncamınızda olan disk sahəsində yaradıla bilməz. Bu nüvə matrisinin məlumatdan asılı təbiətinin Nyström seçməsinə niyə çətinləşdirdiyini müzakirə edin. Spektral klasterləşmə üçün Nyström seçməsinin təxmini yaxınlaşmasını təklif edin. [Sualın son hissəsinin cavabı birmənalı deyil.]

11. Diaqonallaşdırıla bilməyən istiqamətlənmiş qrafın 2×2 ölçülü qonşuluq matrisinə bir misal verin.

12. İkitərəfli qraf təpə çoxluğu $V_1 \cup V_2$ şəklində bölünmüş $G = (V_1 \cup V_2)$ qrafı kimi təyin olunur ki, E -dəki heç bir til tək bir bölmənin təpələri arasında mövcud olmasın. Başqa sözlə, bütün $(i, j) \in E$ üçün i və j -nin hər ikisi V_1 -dən götürülə bilməz, həmçinin i və j -nin hər ikisi V_2 -dən götürülə bilməz. Göstərin ki, əgər λ istiqamətlənməmiş ikitərəfli qrafın qonşuluq matrisinin məxsusi qiymətidirsə, onda λ da məxsusi qiymətdir.
13. **Dərəcə şərtləndirilməsi:** Tutaq ki, sizdə istiqamətlənməmiş qrafın A qonşuluq matrisi var. Perron-Frobenius teoremindən istifadə edərək müzakirə edin ki, hər bir i təpəsinin (çəkili) dərəcəsini i -ci diaqonal elementə əlavə etmək niyə müsbət yarımdeqiq matrislə nəticələnir. Fəslin mətnində A -nın hər bir elementinin işarəsini dəyişməyin və dərəcə matrisini əlavə etməyin müsbət yarımdeqiq Laplasyan ilə nəticələndiyi artıq göstərilmişdir. Həmçinin Perron-Frobenius teoremini istifadə edərək normallaşdırılmamış Laplasyanın müsbət yarımdeqiq olmasının alternativ sübutunu təqdim edin.
14. Tutaq ki, sizə istiqamətlənməmiş (və ehtimal ki, çəkili) qrafın qonşuluq matrisinin $A \approx UU^T$ simmetrik faktorizasiyası verilib ki, burada A -nın bütün elementləri (sıfır diaqonal elementləri istisna olmaqla) UU^T vasitəsilə yaxşı yaxınlaşdırılır. Bundan əlavə, $n \times k$ ölçülü U matrisinin bütün elementləri qeyri-mənfidir. Müzakirə edin ki, hər biri rəngi 1 olan k qonşuluq matrisinin cəmi kimi A -nı ifadə etmək üçün bu faktorizasiyadan necə istifadə edə bilərsiniz. U -ya baxmaqla qrafın ehtimal ki, üst-üstə düşən klasterləşməsini yaratmaq üçün bu dekompozisiyadan necə istifadə edə biləcəyinizi müzakirə edin. Qeyri-mənfi matris faktorizasiyasının interpretasiya üstünlüklərini müzakirə edin.
15. Tutaq ki, P istiqamətlənməmiş və əlaqəli qrafın stoxastik keçid matrisidir. Göstərin ki, P -nin əsas sol məxsusi vektordan (yəni PageRank vektorundan) başqa bütün sol məxsusi vektorlarının vektor komponentlərinin cəmi 0-a bərabərdir. [Göstəriş: Matrisin sol məxsusi vektorları və sağ məxsusi vektorları arasındakı bucaqlar necədir?]
16. İstiqamətlənməmiş qrafın spektral klasterləşməsinin simmetrik normallaşdırılmış qonşuluq matrisi S olsun. Bəzi hallarda, S -də məxsusi vektor çıxarılmasından əldə edilən xüsusiyyətlərə k -means alqoritmini tətbiq etdikdə klasterlər aydın şəkildə ayrılır. Belə hallarda məxsusi vektorun çıxarılması üçün S -in əvəzinə $(C + S)(C + S)$ istifadə etməyin üstünlüklərini müzakirə etmək üçün 9-cu fəsildən nüvə intuisiyasından istifadə edin. Burada $C \geq 0$ sabit qiymətlər matrisidir. [Göstəriş: k -means alqoritmı xətti ayrılan klasterlərlə ən yaxşı işləyir. Şəkil 9.4-ə baxın.]
17. $n \times n$ ölçülü iki simmetrik A və B matrisini nəzərdən keçirin ki, B həm də müsbət dəqiqdir. Göstərin ki, BA -nın simmetrik olması vacib deyil, lakin o, həqiqi məxsusi qiymətlərlə diaqonallaşdırıla bilər. [Göstəriş: Bu, B -ni tərs dərəcə matrisinə, A -nı isə qonşuluq matrisinə təyin etməklə stoxastik keçid matrislərinin həqiqi məxsusi qiymətlərə malik olmasının sübutunun ümumiləşdirilməsidir.]
18. Tutaq ki, A 20 təpədən ibarət istiqamətlənmiş qrafın 20×20 ölçülü binar qonşuluq matrisidir. $(I - A^{20})(I - A)^{-1}$ matrisini qrafdağı gəzintilər baxımından şərh edin. Güclü əlaqəli qraf üçün bu matrisin hər hansı xüsusi xassələri olacaqmı? Cəbri olaraq aşağıdakı bərabərliyin nə üçün doğru olduğunu əsaslandırın:

$$(I - A^{20})(I - A)^{-1} = (I - A)^{-1}(I - A^{20})$$

19. Əvvəlki fəslin 13-cü tapşırığı simmetrik qeyri-mənfi matris faktorizasiyasını təqdim edir ki, o, həmçinin spektral klasterləşmədə istifadə olunan simmetrik normallaşdırılmış $S \approx UU^T$ qonşuluq matrisini faktorizasiya etmək üçün də istifadə oluna bilər. Burada U $n \times k$ ölçülü qeyri-mənfi faktor matrisidir. Müzakirə edin ki, U -nın hər bir sütununun (böyüklüyünə görə) ən yüksək r komponenti niyə qrafda birbaşa r ölçülü klasterləşdirilmiş təpə yığımlarını təmin edir.
20. (i) n təpəli istiqamətlənməmiş tsikldə və (ii) hər biri $n - 1$ təpənin hər biri ilə istiqamətlənməmiş til vasitəsilə əlaqələndirilmiş tək mərkəzi təpədə hər bir təpənin PageRank qiymətini tapın. Hər bir halda 0 yenidənbaşlama ehtimalı (restart probability) ilə PageRank-i hesablayın.
21. **İşarələnmiş şəbəkənin yerləşdirilməsi:** Tutaq ki, tillərində həm müsbət, həm də mənfi çəkiləri olan qrafınız var. Spektral klasterləşmə üçün “zəif tilləri” aradan qaldırmaq və qrafı simmetrik şəkildə normallaşdırmaq üçün istifadə olunan alqoritmlərin modifikasiyalarını təklif edin. Alınan qraf ortoqonal məxsusi vektorlar və həqiqi məxsusi qiymətlərlə diaqonallaşdırıla bilən olacaqmı? Birinci məxsusi vektor haqqında hər hansı xüsusi bir cəhət varmı? [Bu, çoxsaylı həlləri olan açıq tipli sualdır.]
22. Heterogen şəbəkə yerləşdirilməsi: Bir çox növ istiqamətlənmiş/istiqamətlənməmiş tillərə malik olan sosial şəbəkə qrafını nəzərdən keçirin (məsələn, istiqamətlənməmiş dostluq əlaqələri, istiqamətlənmiş mesajlaşma əlaqələri və istiqamətlənmiş “bəyənmə” əlaqələri). Hər bir təpənin yerləşdirilməsini çıxarmaq üçün paylaşılan matris faktorizasiyası alqoritmi təklif edin (bax: 8-ci Fəsil). Parametrləri necə tənzimlərdiniz? [Bu, çoxsaylı həlləri olan açıq tipli sualdır.]

